

Arquiteturas de Deep Learning

APRENDIZADO DE MÁQUINA

Zenilton K. G. Patrocínio Jr

zenilton@pucminas.br

Aprendizado de Máquina Supervisionado

Inicia-se com um conjunto de “observações” $\mathcal{X}$ e um conjunto de “alvos” ou “rótulos” $\mathcal{Y}$

O interesse está em conhecer como as observações determinam os alvos

Aprendizado de Máquina Supervisionado

Inicia-se com um conjunto de “observações” $\mathcal{X}$ e um conjunto de “alvos” ou “rótulos” $\mathcal{Y}$

O interesse está em conhecer como as observações determinam os alvos

Entrada : vários pares (x_i, y_i) em que $x_i \in \mathcal{X}$ e $y_i \in \mathcal{Y}$

Saída : Dada uma nova observação x , deseja-se prever o rótulo correspondente y

Aprendizado de Máquina Supervisionado

Inicia-se com um conjunto de “observações” $\mathcal{X}$ e um conjunto de “alvos” ou “rótulos” $\mathcal{Y}$

O interesse está em conhecer como as observações determinam os alvos

Entrada : vários pares (x_i, y_i) em que $x_i \in \mathcal{X}$ e $y_i \in \mathcal{Y}$

Saída : Dada uma nova observação x , deseja-se prever o rótulo correspondente y

Tipicamente observações são “baratas” enquanto alvos são “caros” e não-observáveis.

⇒ Dessa forma, predições corretas apresentam valor econômico

Problemas de Predição – Exemplos

Observação – Espaço $\mathcal{X}$:

Imagens

Alvo – Espaço $\mathcal{Y}$:

Classe da imagem: “gato”, “cachorro”, ...

Problemas de Predição – Exemplos

Observação – Espaço $\mathcal{X}$:

Imagens

Imagens

Alvo – Espaço $\mathcal{Y}$:

Classe da imagem: “gato”, “cachorro”, ...

Rótulo descritivo: “crianças jogando futebol”

Problemas de Predição – Exemplos

Observação – Espaço $\mathcal{X}$:

Imagens

Imagens

Imagens de Faces

Alvo – Espaço $\mathcal{Y}$:

Classe da imagem: “gato”, “cachorro”, ...

Rótulo descritivo: “crianças jogando futebol”

Identidade do usuário

Problemas de Predição – Exemplos

Observação – Espaço $\mathcal{X}$:

Imagens

Imagens

Imagens de Faces

Imagens Naturais

Alvo – Espaço $\mathcal{Y}$:

Classe da imagem: “gato”, “cachorro”, ...

Rótulo descritivo: “crianças jogando futebol”

Identidade do usuário

Imagens estilizadas (p.ex. desenhos animados)

Problemas de Predição – Exemplos

Observação – Espaço $\mathcal{X}$:

Imagens

Imagens

Imagens de Faces

Imagens Naturais

Sons da Fala Humana

Alvo – Espaço $\mathcal{Y}$:

Classe da imagem: “gato”, “cachorro”, ...

Rótulo descritivo: “crianças jogando futebol”

Identidade do usuário

Imagens estilizadas (p.ex. desenhos animados)

Transcrição textual da fala

Problemas de Predição – Exemplos

Observação – Espaço $\mathcal{X}$:

Imagens

Imagens

Imagens de Faces

Imagens Naturais

Sons da Fala Humana

Sentença em inglês

Alvo – Espaço $\mathcal{Y}$:

Classe da imagem: “gato”, “cachorro”, ...

Rótulo descritivo: “crianças jogando futebol”

Identidade do usuário

Imagens estilizadas (p.ex. desenhos animados)

Transcrição textual da fala

Tradução para o português

Problemas de Predição – Exemplos

Observação – Espaço $\mathcal{X}$:

Imagens

Imagens

Imagens de Faces

Imagens Naturais

Sons da Fala Humana

Sentença em inglês

Dados Demográficos: idade, renda

Alvo – Espaço $\mathcal{Y}$:

Classe da imagem: “gato”, “cachorro”, ...

Rótulo descritivo: “crianças jogando futebol”

Identidade do usuário

Imagens estilizadas (p.ex. desenhos animados)

Transcrição textual da fala

Tradução para o português

Outras informações: nível educacional, emprego

Problemas de Predição – Exemplos

Observação – Espaço $\mathcal{X}$:

Imagens

Imagens

Imagens de Faces

Imagens Naturais

Sons da Fala Humana

Sentença em inglês

Dados Demográficos: idade, renda

Dados sobre dieta e estilo de vida

Alvo – Espaço $\mathcal{Y}$:

Classe da imagem: “gato”, “cachorro”, ...

Rótulo descritivo: “crianças jogando futebol”

Identidade do usuário

Imagens estilizadas (p.ex. desenhos animados)

Transcrição textual da fala

Tradução para o português

Outras informações: nível educacional, emprego

Risco de doenças cardíacas

Aprendizado Estatístico

Assume-se que x e y são obtidas a partir de **amostras de variáveis randômicas** X e Y

Estas variáveis randômicas possuem uma **distribuição conjunta** $P(X, Y)$

Aprendizado Estatístico

Assume-se que x e y são obtidas a partir de **amostras de variáveis randômicas** X e Y

Estas variáveis randômicas possuem uma **distribuição conjunta** $P(X, Y)$

Para predição, deseja-se conhecer pelo menos a distribuição condicional $P(Y|X)$, de forma que se possa determinar a distribuição dos alvos y dada uma observação x

Aprendizado Estatístico

Assume-se que x e y são obtidas a partir de **amostras de variáveis randômicas** X e Y

Estas variáveis randômicas possuem uma **distribuição conjunta** $P(X, Y)$

Para predição, deseja-se conhecer pelo menos a distribuição condicional $P(Y|X)$, de forma que se possa determinar a distribuição dos alvos y dada uma observação x

Uma aproximação $\hat{P}(Y|X)$ para a verdadeira distribuição $P(Y|X)$ é denominada **modelo**

Aprendizado Estatístico

Assume-se que x e y são obtidas a partir de **amostras de variáveis randômicas** X e Y

Estas variáveis randômicas possuem uma **distribuição conjunta** $P(X, Y)$

Para predição, deseja-se conhecer pelo menos a distribuição condicional $P(Y|X)$, de forma que se possa determinar a distribuição dos alvos y dada uma observação x

Uma aproximação $\hat{P}(Y|X)$ para a verdadeira distribuição $P(Y|X)$ é denominada **modelo**

O objetivo do aprendizado estatístico é construir modelos que sejam:

1. Computáveis (e talvez, simples e eficientes); e
2. Capazes de fornecer predições próximas daquelas feitas pela verdadeira distribuição

Função de Predição

Pode-se simplificar a tarefa de modelagem por meio de uma suposição “forte” sobre o modelo $\hat{P}(X, Y)$ de que $y = f(x)$, isto é, y **assume um único valor** para um dado x

Exemplos:

- Regressão Linear: $y = f(x)$ em que f é uma função linear e y é um valor real, $y \in \mathbb{R}$
- Classificador (SVM, Floresta Randômica, etc.): $y = f(x)$ representa a classe predita de x e y é o número/rótulo da classe, $y \in \{1, \dots, k\}$


Abordagem Paramétrica



[32x32x3]

vetor de números
(3072 no total)

$f(\mathbf{x}, \mathbf{W})$



10 números,
indicando “scores”
de cada classe

Abordagem Paramétrica




[32x32x3]

vetor de números
(3072 no total)

imagem

$f(\mathbf{x}, \mathbf{W})$



10 números,
indicando “scores”
de cada classe

Abordagem Paramétrica



[32x32x3]

vetor de números
(3072 no total)

imagem parâmetros
 $f(\mathbf{x}, \mathbf{W})$

10 números,
indicando “scores”
de cada classe


Abordagem Paramétrica: Classificador Linear

$$f(x, W) = Wx$$



[32x32x3]

vetor de números
(3072 no total)



10 números,
indicando “scores”
de cada classe


Abordagem Paramétrica: Classificador Linear

$$f(x, W) = W \boxed{x} \quad \mathbf{3072 \times 1}$$



[32x32x3]

vetor de números
(3072 no total)



10 números,
indicando “scores”
de cada classe


Abordagem Paramétrica: Classificador Linear



[32x32x3]
vetor de números
(3072 no total)

$$\boxed{f(x, W)} = W \boxed{x} \quad \text{3072x1}$$

10x1



10 números,
indicando “scores”
de cada classe

Abordagem Paramétrica: Classificador Linear




[32x32x3]
vetor de números
(3072 no total)

$$\boxed{f(x, W)} = \boxed{W} \boxed{x}$$


10x1 **10x3072** **3072x1**

10 números,
indicando “scores”
de cada classe

Abordagem Paramétrica: Classificador Linear



Abordagem Paramétrica: Classificador Linear



Abordagem Paramétrica: Classificador Linear

Exemplo com 4 pixels de uma imagem e 3 classes (**gato** / **cão** / **navio**)



Imagem de
entrada

?




score – gato

score – cão

score – navio


Abordagem Paramétrica: Classificador Linear

Exemplo com 4 pixels de uma imagem e 3 classes (**gato** / **cão** / **navio**)




Abordagem Paramétrica: Classificador Linear

Exemplo com 4 pixels de uma imagem e 3 classes (**gato** / **cão** / **navio**)




Abordagem Paramétrica: Classificador Linear

Exemplo com 4 pixels de uma imagem e 3 classes (**gato** / **cão** / **navio**)



Abordagem Paramétrica: Classificador Linear

Exemplo com 4 pixels de uma imagem e 3 classes (**gato** / **cão** / **navio**)



Abordagem Paramétrica: Classificador Linear

Exemplo de “scores” de classe para 3 imagens com uma matriz W aleatória



$$f(x_i, W, b) = Wx_i + b$$

avião	-3, 45	-0, 51	3, 42
carro	-8, 87	6, 04	4, 64
pássaro	0, 09	5, 31	2, 65
gato	2, 9	-4, 22	5, 1
corsa	4, 48	-4, 19	2, 64
cão	8, 02	3, 58	5, 55
rã	3, 78	4, 49	-4, 34
cavalo	1, 06	-4, 37	-1, 5
navio	-0, 36	-2, 09	-4, 79
caminhão	-0, 72	-2, 93	6, 14

Abordagem Paramétrica: Classificador Linear

Exemplo de “scores” de classe para 3 imagens com uma matriz W aleatória



$$f(x_i, W, b) = Wx_i + b$$

avião	-3, 45	-0, 51	3, 42
carro	-8, 87	6, 04	4, 64
pássaro	0, 09	5, 31	2, 65
gato	2, 9	-4, 22	5, 1
corsa	4, 48	-4, 19	2, 64
cão	8, 02	3, 58	5, 55
rã	3, 78	4, 49	-4, 34
cavalo	1, 06	-4, 37	-1, 5
navio	-0, 36	-2, 09	-4, 79
caminhão	-0, 72	-2, 93	6, 14

Abordagem Paramétrica: Classificador Linear

Exemplo de “scores” de classe para 3 imagens com uma matriz W aleatória



$$f(x_i, W, b) = Wx_i + b$$

avião	-3,45	-0,51	3,42
carro	-8,87	6,04	4,64
pássaro	0,09	5,31	2,65
gato	2,9	-4,22	5,1
corsa	4,48	-4,19	2,64
cão	8,02	3,58	5,55
rã	3,78	4,49	-4,34
cavalo	1,06	-4,37	-1,5
navio	-0,36	-2,09	-4,79
caminhão	-0,72	-2,93	6,14



Deve-se encontrar com o treinamento um conjunto de parâmetros ou pesos que consiga obter os melhores resultados de predição

Função de Perda

Pode não haver um valor alvo y “verdadeiro” para uma observação x , ou seja, pode haver vários “diferentes” valores de y para o mesmo x

Função de Perda

Pode não haver um valor alvo y “verdadeiro” para uma observação x , ou seja, pode haver vários “diferentes” valores de y para o mesmo x

Também pode haver ruído ou efeitos não modelados no conjunto de dados; portanto, mesmo se houver um único y para um dado x , pode ser impossível predizê-lo com exatidão

Função de Perda

Pode não haver um valor alvo y “verdadeiro” para uma observação x , ou seja, pode haver vários “diferentes” valores de y para o mesmo x

Também pode haver ruído ou efeitos não modelados no conjunto de dados; portanto, mesmo se houver um único y para um dado x , pode ser impossível predizê-lo com exatidão

Em vez disso, tenta-se prever um valor “próximo” do valor alvo observado

Função de Perda

Neste caso, usa-se durante o treinamento uma **função de perda** para medir a proximidade de tais predições feitas em relação aquelas do conjunto de dados que foram previamente observadas

Função de Perda

Neste caso, usa-se durante o treinamento uma **função de perda** para medir a proximidade de tais predições feitas em relação aquelas do conjunto de dados que foram previamente observadas

Uma **função de perda** mede a diferença entre uma predição do valor alvo e o valor disponível no conjunto de treinamento

Função de Perda

Neste caso, usa-se durante o treinamento uma **função de perda** para medir a proximidade de tais predições feitas em relação aquelas do conjunto de dados que foram previamente observadas

Uma **função de perda** mede a diferença entre uma predição do valor alvo e o valor disponível no conjunto de treinamento


Exemplo: Perda quadrática (ou “**squared loss**”) $L_2(\hat{y}, y) = (\hat{y} - y)^2$ em que $\hat{y} = f(x)$ representa a predição feita pelo modelo para o par de dados (x, y)

Exemplo – Regressão Linear

Nesse tipo de modelo bem simples, $\hat{y} = f(x) = ax + b$ sendo x um valor real, enquanto a e b são constantes reais

Exemplo – Regressão Linear

Nesse tipo de modelo bem simples, $\hat{y} = f(x) = ax + b$ sendo x um valor real, enquanto a e b são constantes reais




Os n pares de dados (x, y) são os pontos **azuis**

Já o modelo é representado pela linha **vermelha**

Exemplo – Regressão Linear

Nesse tipo de modelo bem simples, $\hat{y} = f(x) = ax + b$ sendo x um valor real, enquanto a e b são constantes reais

A perda quadrática $L_2(\hat{y}, y) = (\hat{y} - y)^2$ avalia a diferença (ou distância) entre predição $\hat{y}$ e dado y




Os n pares de dados (x, y) são os pontos **azuis**

Já o modelo é representado pela linha **vermelha**

Exemplo – Regressão Linear

Nesse tipo de modelo bem simples, $\hat{y} = f(x) = ax + b$ sendo x um valor real, enquanto a e b são constantes reais

A perda quadrática $L_2(\hat{y}, y) = (\hat{y} - y)^2$ avalia a diferença (ou distância) entre predição $\hat{y}$ e dado y



Os n pares de dados (x, y) são os pontos **azuis**

Já o modelo é representado pela linha **vermelha**

Exemplo – Regressão Linear

A perda total pode ser obtida somando-se a perda em todos os n pares

$$L = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Exemplo – Regressão Linear

A perda total pode ser obtida somando-se a perda em todos os n pares

$$L = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Uma vez que a predição $\hat{y}_i$ para um x_i qualquer é dada por $ax_i + b$, pode-se rescrever a perda total como

$$L = \sum_{i=1}^n (ax_i + b - y_i)^2$$

Exemplo – Regressão Linear

A perda total pode ser obtida somando-se a perda em todos os n pares

$$L = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Uma vez que a predição $\hat{y}_i$ para um x_i qualquer é dada por $ax_i + b$, pode-se rescrever a perda total como

$$L = \sum_{i=1}^n (ax_i + b - y_i)^2$$

Para se encontrar os valores ótimos de a e b , pode-se aplicar o cálculo diferencial, igualando à zero as derivadas da perda total em relação a e b , isto é

$$\frac{\partial L}{\partial a} = 0 \quad \text{e} \quad \frac{\partial L}{\partial b} = 0$$

Exemplo – Regressão Linear

Dessa forma, para se minimizar a perda e obter os valores ótimos de a e b , deve-se fazer

$$\frac{\partial L}{\partial a} = 2a \sum_{i=1}^n x_i^2 + 2b \sum_{i=1}^n x_i - 2 \sum_{i=1}^n x_i y_i = 0$$

$$\frac{\partial L}{\partial b} = 2a \sum_{i=1}^n x_i + 2bn - 2 \sum_{i=1}^n y_i = 0$$

Exemplo – Regressão Linear

Dessa forma, para se minimizar a perda e obter os valores ótimos de a e b , deve-se fazer

$$\frac{dL}{da} = 2a \sum_{i=1}^n x_i^2 + 2b \sum_{i=1}^n x_i - 2 \sum_{i=1}^n x_i y_i = 0$$

$$\frac{dL}{db} = 2a \sum_{i=1}^n x_i + 2bn - 2 \sum_{i=1}^n y_i = 0$$

Como os somatórios nessas equações são constantes para os n pares de dados, tem-se duas equações **lineares** em a e b , que podem ser facilmente resolvidas

Exemplo – Regressão Linear

Dessa forma, para se minimizar a perda e obter os valores ótimos de a e b , deve-se fazer

$$\frac{dL}{da} = 2a \sum_{i=1}^n x_i^2 + 2b \sum_{i=1}^n x_i - 2 \sum_{i=1}^n x_i y_i = 0$$

$$\frac{dL}{db} = 2a \sum_{i=1}^n x_i + 2bn - 2 \sum_{i=1}^n y_i = 0$$

Como os somatórios nessas equações são constantes para os n pares de dados, tem-se duas equações **lineares** em a e b , que podem ser facilmente resolvidas obtendo-se valores $\tilde{a}$ e $\tilde{b}$

O modelo $f(x) = \tilde{a}x + \tilde{b}$ com estes valores é o **modelo de perda mínima**

Minimização de Risco

Recapitulando... obteve-se o valor das constantes a e b que minimizam a perda quadrática sobre alguns dados que ***nós já possuíamos***

Minimização de Risco

Recapitulando... obteve-se o valor das constantes a e b que minimizam a perda quadrática sobre alguns dados que ***nós já possuíamos***

Porém o que se quer na verdade é predizer os valores de y para observações x que ***nós ainda não dispomos***, isto é, gostaríamos de minimizar a perda esperada sobre novos dados, ou ainda, $\mathbb{E}[(\hat{y} - y)^2]$

Minimização de Risco

Recapitulando... obteve-se o valor das constantes a e b que minimizam a perda quadrática sobre alguns dados que ***nós já possuíamos***

Porém o que se quer na verdade é predizer os valores de y para observações x que ***nós ainda não dispomos***, isto é, gostaríamos de minimizar a perda esperada sobre novos dados, ou ainda, $\mathbb{E}[(\hat{y} - y)^2]$

Tal perda esperada é denominada **risco**

Minimização de Risco

Na verdade, minimizou-se um valor de **perda obtido sobre um número finito de dados disponíveis** que é chamado de **risco empírico**

Minimização de Risco

Na verdade, minimizou-se um valor de **perda obtido sobre um número finito de dados disponíveis** que é chamado de **risco empírico**

Dessa forma, o aprendizado de máquina aproxima modelos que minimizam o risco por meio de modelos que minimizem o risco empírico

Minimização de Risco

Na verdade, minimizou-se um valor de **perda obtido sobre um número finito de dados disponíveis** que é chamado de **risco empírico**

Dessa forma, o aprendizado de máquina aproxima modelos que minimizam o risco por meio de modelos que minimizem o risco empírico

Geralmente, minimizar o risco empírico (perda de dados) em vez do risco real funciona bem, mas pode falhar se:

- A amostra de dados for enviesada, ou
- Não houver dados suficientes para estimar com precisão os parâmetros do modelo

Outro Exemplo – Regressão Linear Multivariada

Neste tipo de modelo, x e y são vetores de dimensões m e k , isto é, $x \in \mathbb{R}^m$ e $y \in \mathbb{R}^k$, sendo o modelo dado por

$$y = Ax$$

em que A é uma matriz de coeficientes (ou parâmetros) de dimensões $k \times m$.

Outro Exemplo – Regressão Linear Multivariada

Neste tipo de modelo, x e y são vetores de dimensões m e k , isto é, $x \in \mathbb{R}^m$ e $y \in \mathbb{R}^k$, sendo o modelo dado por

$$y = Ax$$

em que A é uma matriz de coeficientes (ou parâmetros) de dimensões $k \times m$.

Assim, como antes, o risco empírico é dado pela soma da perda em todos os n pares, ou ainda, (usando perda quadrática)

$$L = \sum_{i=1}^n (Ax_i - y_i)^2 = \sum_{i=1}^n (x_i^T A^T - y_i^T)(Ax_i - y_i)$$

Outro Exemplo – Regressão Linear Multivariada

Neste caso, para se minimizar o valor do risco empírico é necessário se igualar a zero o gradiente de L em relação à matriz A , isto é

$$\nabla_A L = 0$$

considerando, assim, que L é uma função da matriz A

Outro Exemplo – Regressão Linear Multivariada

Neste caso, para se minimizar o valor do risco empírico é necessário se igualar a zero o gradiente de L em relação à matriz A , isto é

$$\nabla_A L = 0$$

considerando, assim, que L é uma função da matriz A

O gradiente $\nabla_A L(A)$ representa o vetor de derivadas parciais

$$\nabla_A L(A) = \left[\frac{\partial L}{\partial A_{11}}, \frac{\partial L}{\partial A_{12}}, \dots, \frac{\partial L}{\partial A_{21}}, \frac{\partial L}{\partial A_{22}}, \dots \right]^T$$

Outro Exemplo – Regressão Linear Multivariada

Neste caso, para se minimizar o valor do risco empírico é necessário se igualar a zero o gradiente de L em relação à matriz A , isto é

$$\nabla_A L = 0$$

considerando, assim, que L é uma função da matriz A

O gradiente $\nabla_A L(A)$ representa o vetor de derivadas parciais

$$\nabla_A L(A) = \left[\frac{\partial L}{\partial A_{11}}, \frac{\partial L}{\partial A_{12}}, \dots, \frac{\partial L}{\partial A_{21}}, \frac{\partial L}{\partial A_{22}}, \dots \right]^T$$

em que, por exemplo, $\frac{\partial L}{\partial A_{11}}$ mede o quão rápido varia a perda L em relação a uma variação do coeficiente A_{11} da matriz A


Outro Exemplo – Regressão Linear Multivariada

Quando $\nabla_A L(A) = 0$, então todas as derivadas parciais são nulas, ou ainda, a perda não se modifica em nenhuma direção

Outro Exemplo – Regressão Linear Multivariada

Quando $\nabla_A L(A) = 0$, então todas as derivadas parciais são nulas, ou ainda, a perda não se modifica em nenhuma direção


A superfície da perda aparece em azul.
Os gradientes são mostrados abaixo como setas vermelhas.
O gradiente é zero no mínimo.



Outro Exemplo – Regressão Linear Multivariada

Quando $\nabla_A L(A) = 0$, então todas as derivadas parciais são nulas, ou ainda, a perda não se modifica em nenhuma direção

A superfície da perda aparece em azul.
Os gradientes são mostrados abaixo como setas vermelhas.
O gradiente é zero no mínimo.




Outro Exemplo – Regressão Linear Multivariada

Quando $\nabla_A L(A) = 0$, então todas as derivadas parciais são nulas, ou ainda, a perda não se modifica em nenhuma direção

Portanto, obteve-se um ótimo local

A superfície da perda aparece em azul.
Os gradientes são mostrados abaixo como setas vermelhas.
O gradiente é zero no mínimo.




Outro Exemplo – Regressão Linear Multivariada

Quando $\nabla_A L(A) = 0$, então todas as derivadas parciais são nulas, ou ainda, a perda não se modifica em nenhuma direção

Portanto, obteve-se um ótimo local (ou, pelo menos, um ponto de sela)

A superfície da perda aparece em azul.
Os gradientes são mostrados abaixo como setas vermelhas.
O gradiente é zero no mínimo.



Função de Perda de Entropia Cruzada

Suponha que a predição $\hat{y} = f(x)$ seja a **probabilidade de x ser rotulado na classe alvo** em um problema com duas classes

Função de Perda de Entropia Cruzada

Suponha que a predição $\hat{y} = f(x)$ seja a **probabilidade de x ser rotulado na classe alvo** em um problema com duas classes

Dessa forma, é obtida a **Perda de Entropia Cruzada** (ou “**cross-entropy loss**”)

$$L = - \sum_{i=1}^n y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)$$

Função de Perda de Entropia Cruzada

Suponha que a predição $\hat{y} = f(x)$ seja a **probabilidade de x ser rotulado na classe alvo** em um problema com duas classes

Dessa forma, é obtida a **Perda de Entropia Cruzada** (ou “**cross-entropy loss**”)

$$L = - \sum_{i=1}^n y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)$$

Genericamente, a **Perda de Entropia Cruzada** compara uma distribuição alvo y_i (que pode não ser binária) com uma distribuição $\hat{y}$ dada pelo modelo

Função de Perda de Articulação

A **função perda de articulação** (“*hinge loss*”) usa a noção “margem máxima” buscando obter fronteiras com a maior distância dos dados

Função de Perda de Articulação

A **função perda de articulação** (“**hinge loss**”) usa a noção “margem máxima” buscando obter fronteiras com a maior distância dos dados

A noção de **margem** pode ser representada pela diferença entre o “score” da classe correta e uma outra classe qualquer

Função de Perda de Articulação

A **função perda de articulação** (“**hinge loss**”) usa a noção “margem máxima” buscando obter fronteiras com a maior distância dos dados

A noção de **margem** pode ser representada pela diferença entre o “score” da classe correta e uma outra classe qualquer

Seja y a classe correta correspondendo a x e j uma outra classe qualquer.
Então a perda para a classe j é dada por
 $\max(0, f_j(x) - f_y(x) + 1)$

Função de Perda de Articulação

A **função perda de articulação** (“**hinge loss**”) usa a noção “margem máxima” buscando obter fronteiras com a maior distância dos dados

A noção de **margem** pode ser representada pela diferença entre o “score” da classe correta e uma outra classe qualquer

Seja y a classe correta correspondendo a x e j uma outra classe qualquer. Então a perda para a classe j é dada por $\max(0, f_j(x) - f_y(x) + 1)$

Somando-se para todas as classes j que foram diferente de y , obtém-se

$$L = \sum_{j \neq y} \max(0, f_j(x) - f_y(x) + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$
são




gato	3,2	1,3	2,2
carro	5,1	4,9	2,5
rã	-1,7	2,0	-3,1

Valores em negrito são
“scores” para a classe correta.

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



gato	3,2	1,3	2,2
carro	5,1	4,9	2,5
rã	-1,7	2,0	-3,1

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são

$x_i \rightarrow$				
$y_i \rightarrow$	gato	3,2	1,3	2,2
	carro	5,1	4,9	2,5
	rã	-1,7	2,0	-3,1

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



y_i → gato 3,2 1,3 2,2

j → carro 5,1 **4,9** 2,5

rã -1,7 2,0 **-3,1**

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



y_i → gato 3,2 1,3 2,2

j → carro 5,1 **4,9** 2,5

 rã -1,7 2,0 **-3,1**

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \max(0, 5,1 - 3,2 + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são

	x_i			
y_i	gato	3,2	1,3	2,2
j	carro	5,1	4,9	2,5
	rã	-1,7	2,0	-3,1

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \max(0, 5,1 - 3,2 + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são

$x_i \rightarrow$				
$y_i \rightarrow$	gato	3,2	1,3	2,2
	carro	5,1	4,9	2,5
$j \rightarrow$	rã	-1,7	2,0	-3,1

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \max(0, 5,1 - 3,2 + 1) + \max(0, -1,7 - 3,2 + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são

	x_i			
y_i	gato	3,2	1,3	2,2
	carro	5,1	4,9	2,5
j	rã	-1,7	2,0	-3,1

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \max(0, 5,1 - 3,2 + 1) + \max(0, -1,7 - 3,2 + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



y_i →	gato	3,2	1,3	2,2
	carro	5,1	4,9	2,5
	rã	-1,7	2,0	-3,1

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$\begin{aligned} L_i &= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) \\ &= \max(0, 5,1 - 3,2 + 1) + \max(0, -1,7 - 3,2 + 1) \\ &= \max(0, 2,9) + \max(0, -3,9) \\ &= 2,9 + 0 \\ &= 2,9 \end{aligned}$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são

	$x_i \rightarrow$			
$y_i \rightarrow$	gato	3,2	1,3	2,2
	carro	5,1	4,9	2,5
	rã	-1,7	2,0	-3,1
	Perda:	2,9		

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$\begin{aligned} L_i &= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) \\ &= \max(0, 5,1 - 3,2 + 1) + \max(0, -1,7 - 3,2 + 1) \\ &= \max(0, 2,9) + \max(0, -3,9) \\ &= 2,9 + 0 \\ &= 2,9 \end{aligned}$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$
são



gato	3,2	1,3	2,2
-------------	------------	-----	-----

$y_i \rightarrow$ carro	5,1	4,9	2,5
--------------------------------	-----	------------	-----

rã	-1,7	2,0	-3,1
-----------	------	-----	-------------

Perda: 2,9

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



gato	3,2	1,3	2,2
-------------	------------	-----	-----

$y_i \rightarrow$ carro	5,1	4,9	2,5
--------------------------------	-----	------------	-----

rã	-1,7	2,0	-3,1
-----------	------	-----	-------------

Perda: 2,9

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \max(0, 1,3 - 4,9 + 1) +$$

$$\max(0, 2,0 - 4,9 + 1)$$

$$= \max(0, -2,6) + \max(0, -1,9)$$



$$= 0 + 0$$

$$= 0$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são

				
		x_i 		
y_i 	gato	3,2	1,3	2,2
	carro	5,1	4,9	2,5
	rã	-1,7	2,0	-3,1
	Perda:	2,9	0	

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)


A perda de articulação tem a seguinte forma:

$$\begin{aligned} L_i &= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) \\ &= \max(0, 1,3 - 4,9 + 1) + \\ &\quad \max(0, 2,0 - 4,9 + 1) \\ &= \max(0, -2,6) + \max(0, -1,9) \\ &= 0 + 0 \\ &= 0 \end{aligned}$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



gato	3,2	1,3	2,2
------	-----	-----	-----

carro	5,1	4,9	2,5
-------	-----	------------	-----

$y_i \rightarrow$ rã	-1,7	2,0	-3,1
----------------------	------	-----	-------------

Perda:	2,9	0	
---------------	------------	----------	--

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)


A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



gato	3,2	1,3	2,2
------	-----	-----	-----

carro	5,1	4,9	2,5
-------	-----	-----	-----

$y_i \rightarrow$ rã	-1,7	2,0	-3,1
----------------------	------	-----	------

Perda:	2,9	0	
--------	-----	---	--

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro)

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \max(0, 2,2 - (-3,1) + 1) +$$

$$\max(0, 2,5 - (-3,1) + 1)$$

$$= \max(0, 6,3) + \max(0, 6,6)$$


$$= 6,3 + 6,6$$

$$= 12,9$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



gato	3,2	1,3	2,2
------	-----	-----	-----

carro	5,1	4,9	2,5
-------	-----	-----	-----

$y_i \rightarrow$ rã	-1,7	2,0	-3,1
----------------------	------	-----	------

Perda:	2,9	0	12,9
--------	-----	---	------

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro),

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \max(0, 2,2 - (-3,1) + 1) +$$

$$\max(0, 2,5 - (-3,1) + 1)$$

$$= \max(0, 6,3) + \max(0, 6,6)$$


$$= 6,3 + 6,6$$

$$= 12,9$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$ são



gato	3,2	1,3	2,2
carro	5,1	4,9	2,5
rã	-1,7	2,0	-3,1
Perda:	2,9	0	12,9

Dada uma amostra (x_i, y_i) em que x_i é a imagem e y_i é o rótulo da classe (um valor inteiro),

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Assim a perda total é dada pela soma de todas as perdas

$$L = \sum_{i=1}^N L_i$$

$$L = 2,9 + 0 + 12,9 = 15,8$$

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$
são



gato	3,2	1,3	2,2
carro	5,1	4,9	2,5
rã	-1,7	2,0	-3,1
Perda:	2,9	0	12,9

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

P1: Que ocorre se utilizar a média ao invés da simples soma?

Exemplo – Função de Perda de Articulação

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$
são



gato	3,2	1,3	2,2
carro	5,1	4,9	2,5
rã	-1,7	2,0	-3,1
Perda:	2,9	0	12,9

A perda de articulação tem a seguinte forma:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

P1: Que ocorre se utilizar a média ao invés da simples soma?

$$L = \frac{1}{N} \sum_{i=1}^N L_i$$

$$L = (2,9 + 0 + 12,9) / 3 = 5,3$$

Função *Softmax*

A **função softmax** é uma função que recebe como entrada um vetor e transforma essa entrada em uma **distribuição de probabilidade**

Função *Softmax*

A **função softmax** é uma função que recebe como entrada um vetor e transforma essa entrada em uma **distribuição de probabilidade**

Seja $f_j(x)$ uma estimativa da probabilidade que x pertença a classe j

Função *Softmax*

A **função softmax** é uma função que recebe como entrada um vetor e transforma essa entrada em uma **distribuição de probabilidade**

Seja $f_j(x)$ uma estimativa da probabilidade que x pertença a classe j

A **função softmax** sobre o vetor de “scores” $(s_1, \dots, s_k)$ é dada por

$$f_j(x) = \frac{\exp(s_j)}{\exp(s_1) + \exp(s_2) + \dots + \exp(s_k)} \quad \text{sendo que} \quad \sum_{j=1}^k f_j(x) = 1$$

Função *Softmax*

A **função softmax** é uma função que recebe como entrada um vetor e transforma essa entrada em uma **distribuição de probabilidade**

Seja $f_j(x)$ uma estimativa da probabilidade que x pertença a classe j

A **função softmax** sobre o vetor de “scores” $(s_1, \dots, s_k)$ é dada por

$$f_j(x) = \frac{\exp(s_j)}{\exp(s_1) + \exp(s_2) + \dots + \exp(s_k)} \quad \text{sendo que} \quad \sum_{j=1}^k f_j(x) = 1$$

O nome “softmax” indica que se algum “score” s_j for razoavelmente maior que os demais, a saída será próxima de $(0, \dots, 1, \dots, 0)$ em que o 1 se encontra na j posição

Classificador *Softmax*



gato **3,2**

carro **5,1**

rã **-1,7**

“Scores” $\equiv$ probabilidades logarítmicas não normalizadas das classes

$$s = f(x, W)$$

Classificador *Softmax*



gato **3,2**

carro **5,1**

rã **-1,7**

“Scores” $\equiv$ probabilidades logarítmicas não normalizadas das classes

$$P(Y = k|X = x_i) = \frac{e^{s_{yi}}}{\sum_j e^{s_j}} \text{ em que } s = f(x, W)$$

Classificador *Softmax*



gato 3,2

carro 5,1

rã -1,7

“Scores” $\equiv$ probabilidades logarítmicas não normalizadas das classes

$$P(Y = k|X = x_i) = \frac{e^{s_{yi}}}{\sum_j e^{s_j}} \text{ em que } s = f(x, W)$$

Deseja-se maximizar a log-verossimilhança, ou ainda, **minimizar a função de log-verossimilhança negativa** da classe correta (considerando uma função de perda)

$$L_i = -\log P(Y = y_i | X = x_i)$$

Classificador *Softmax*



gato 3,2

carro 5,1

rã -1,7

“Scores” $\equiv$ probabilidades logarítmicas não normalizadas das classes

$$P(Y = k|X = x_i) = \frac{e^{s y_i}}{\sum_j e^{s_j}} \text{ em que } s = f(x, W)$$

Deseja-se maximizar a log-verossimilhança, ou ainda, **minimizar a função de log-verossimilhança negativa** da classe correta (considerando uma função de perda)

$$L_i = -\log P(Y = y_i | X = x_i)$$

Portanto

$$L_i = -\log \left(\frac{e^{s y_i}}{\sum_j e^{s_j}} \right)$$

Exemplo – Classificador *Softmax*




gato **3,2**

carro **5,1**


rã **-1,7**

probabilidades log
não normalizadas

Exemplo – Classificador *Softmax*



Exemplo – Classificador *Softmax*




Exemplo – Classificador *Softmax*



$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

Função *Softmax*



Exemplo de Código – Função de Perda de Articulação

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Código em Python (usando numpy)

```
def L_i_vectorized(x, y, W):  
    scores = W.dot(x)  
    margins = np.maximum(0, scores - scores[y] + 1)  
    margins[y] = 0  
    loss_i = np.sum(margins)  
    return loss_i
```

Problema com Cálculo da Perda

$$f(x, W) = Wx$$

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1)$$

Problema com Cálculo da Perda

$$f(x, W) = Wx$$

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1)$$



Problema com Cálculo da Perda

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$
são



gato	3,2	1,3	2,2
carro	5,1	4,9	2,5
rã	-1,7	2,0	-3,1
Perda:	2,9	0	12,9

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Antes:

$$\begin{aligned} &= \max(0, 1,3 - 4,9 + 1) + \\ &\quad \max(0, 2,0 - 4,9 + 1) \\ &= \max(0, -2,6) + \max(0, -1,9) \\ &= 0 + 0 \\ &= 0 \end{aligned}$$

Problema com Cálculo da Perda

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$
são



gato	3,2	1,3	2,2
carro	5,1	4,9	2,5
rã	-1,7	2,0	-3,1
Perda:	2,9	0	12,9

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Antes:

$$\begin{aligned} &= \max(0, 1,3 - 4,9 + 1) + \\ &\quad \max(0, 2,0 - 4,9 + 1) \\ &= \max(0, -2,6) + \max(0, -1,9) \\ &= 0 + 0 \\ &= 0 \end{aligned}$$

Com W duas vezes maior:

$$\begin{aligned} &= \max(0, 2,6 - 9,8 + 1) + \\ &\quad \max(0, 4,0 - 9,8 + 1) \\ &= \max(0, -6,2) + \max(0, -4,8) \\ &= 0 + 0 \\ &= 0 \end{aligned}$$

Problema com Cálculo da Perda

Suponha: 3 imagens treino e 3 classes

Para algum W , “scores” $s = f(x, W) = Wx$
são



gato	3,2	1,3	2,2
carro	5,1	4,9	2,5
rã	-1,7	2,0	-3,1
Perda:	2,9	0	12,9


$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Antes:

$$\begin{aligned} &= \max(0, 1,3 - 4,9 + 1) + \\ &\quad \max(0, 2,0 - 4,9 + 1) \\ &= \max(0, -2,6) + \max(0, -1,9) \\ &= 0 + 0 \\ &= 0 \end{aligned}$$

Com W duas vezes maior:

$$\begin{aligned} &= \max(0, 2,6 - 9,8 + 1) + \\ &\quad \max(0, 4,0 - 9,8 + 1) \\ &= \max(0, -6,2) + \max(0, -4,8) \\ &= 0 + 0 \\ &= 0 \end{aligned}$$



Problema com Cálculo da Perda

$$f(x, W) = Wx$$

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1)$$



Essa perda tem uma dependência linear de $\|w^j\|_2$ e essa dependência é geralmente negativa, portanto, a minimização do risco tende a fazer crescer $\|w^j\|_2$

Problema com Cálculo da Perda

$$f(x, W) = Wx$$

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1)$$



Essa perda tem uma dependência linear de $\|w^j\|_2$ e essa dependência é geralmente negativa, portanto, a minimização do risco tende a fazer crescer $\|w^j\|_2$

Pode-se tentar corrigir isso usando um termo de regularização $\lambda \|W\|_2$ em que a norma da matrix $\|\cdot\|_2$ representa soma dos quadrados de seus elementos

Problema com Cálculo da Perda

$$f(x, W) = Wx$$

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1)$$



Essa perda tem uma dependência linear de $\|w^j\|_2$ e essa dependência é geralmente negativa, portanto, a minimização do risco tende a fazer crescer $\|w^j\|_2$

Pode-se tentar corrigir isso usando um termo de regularização $\lambda \|W\|_2$ em que a norma da matrix $\|\cdot\|_2$ representa soma dos quadrados de seus elementos

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1) + \lambda \|W\|_2$$

Força ou Peso de Regularização

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1) + \lambda R(W)$$

Força ou Peso de Regularização

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1) + \lambda R(W)$$

**λ = força de regularização
(hiperparâmetro)**

Força ou Peso de Regularização

$$L = \frac{1}{N} \sum_{i=1}^N \sum_{j \neq y_i} \max(0, f(x_i, W)_j - f(x_i, W)_{y_i} + 1) + \lambda R(W)$$

λ = força de regularização
(hiperparâmetro)

Regularizações comuns:

- L2 (Ridge)

$$R(W) = \sum_k \sum_l W_{k,l}^2$$

- L1 (Lasso)

$$R(W) = \sum_k \sum_l |W_{k,l}|$$

- L1 + L2 (*Elastic net*)

$$R(W) = \sum_k \sum_l \beta W_{k,l}^2 + |W_{k,l}|$$

- Técnicas mais recentes: **Dropout**, ...

Recapitulando

- Tem-se um conjunto de dados (x, y)

Recapitulando

- Tem-se um conjunto de dados (x, y)
- Uma função de “**score**”

p.ex. $s = f(x; W) = Wx$

Recapitulando

- Tem-se um conjunto de dados (x, y)
- Uma função de “**score**” p.ex. $s = f(x; W) = Wx$
- Uma função de **perda**

Log-Ver Neg $L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$

Hinge $L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$

Recapitulando

- Tem-se um conjunto de dados (x, y)
- Uma função de “**score**” p.ex. $s = f(x; W) = Wx$
- Uma função de **perda**

Log-Ver Neg $L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$

Hinge $L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$

Perda Total $L = \frac{1}{N} \sum_{i=1}^N L_i + R(W)$

Recapitulando

- Tem-se um conjunto de dados (x, y)
- Uma função de “**score**”
- Uma função de **perda**

p.ex. $s = f(x; W) = Wx$

Log-Ver Neg $L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$

Hinge $L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$

Perda Total $L = \frac{1}{N} \sum_{i=1}^N L_i + R(W)$

Grafo de Computação
da Função de Perda

