



Regressão Linear Simples



Por que regressão linear simples ainda é fundamental?

Apesar de sua formulação simples, a regressão linear simples continua sendo **um dos pilares da análise estatística e da ciência de dados**, por três razões centrais:

- **Base conceitual de modelos mais complexos**

Grande parte dos modelos usados em Data Science (regressão múltipla, regularização, modelos lineares generalizados, até redes neurais) parte da mesma ideia fundamental:

modelar o valor médio esperado de uma variável resposta a partir de variáveis explicativas.

Por que regressão linear simples ainda é fundamental?

■ Poder explicativo e interpretabilidade

Diferente de muitos modelos de machine learning, a regressão linear permite responder perguntas como:

- *Quanto Y muda quando X aumenta uma unidade?*
- *Esse efeito é estatisticamente relevante?*
- *O sinal do efeito faz sentido no contexto do problema?*

Por que regressão linear simples ainda é fundamental?

▪ Ferramenta de leitura e diagnóstico dos dados

Mesmo quando o modelo final não será linear, a regressão simples ajuda a:

- Entender tendências iniciais;
- Detectar relações espúrias;
- Avaliar se um problema é essencialmente linear ou não.

Mensagem-chave: antes de prever bem, é preciso **entender bem**.

Qual é o problema central da regressão?

Em fenômenos reais, a variável resposta **não assume um único valor fixo** para cada valor da variável explicativa.

Em vez disso, observamos **variabilidade**.

Por isso, a regressão linear simples **não tenta prever valores exatos**, mas sim **modelar o comportamento médio da variável resposta em função da variável explicativa**.

A pergunta correta da regressão

A regressão **não pergunta**:

✗ “Qual será exatamente o valor de Y quando $X = x$?”

Ela pergunta:

✓ “Qual é o valor médio esperado de Y quando X assume determinado valor?”

Essa distinção é fundamental para compreender:

- o papel do erro aleatório;
- a existência de resíduos;
- os limites do modelo.

O modelo de regressão linear simples

A regressão linear simples é expressa por:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Essa equação descreve **como o valor observado de Y é gerado**, segundo o modelo.

Y — Variável resposta

É a variável que desejamos: explicar, compreender, ou prever.

Exemplos: tempo de resposta de um sistema, receita mensal, consumo de energia, taxa de conversão.

O modelo de regressão linear simples

A regressão linear simples é expressa por:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

X — Variável explicativa

É a variável usada para explicar a variação média de Y .

Importante:

O modelo **não afirma** que X é a única causa de Y , apenas que ela está associada ao seu comportamento médio.

O modelo de regressão linear simples

A regressão linear simples é expressa por:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

β_0 — Intercepto ou coeficiente linear

Representa o valor médio esperado de Y quando $X = 0$.

Observações importantes:

- Nem sempre tem interpretação prática;
- Pode representar apenas um ponto matemático necessário para ajustar a reta;
- Ainda assim, é essencial para o modelo.

O modelo de regressão linear simples

A regressão linear simples é expressa por:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

β_1 —Inclinação ou coeficiente angular

Indica a variação média esperada em Y para cada aumento unitário em X.

Exemplo:

$$\beta_1 = 2,5$$

→ a cada aumento de 1 unidade em X, espera-se um aumento médio de 2,5 unidades em Y.

Essa interpretação é condicional ao intervalo observado dos dados.

O modelo de regressão linear simples

A regressão linear simples é expressa por:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

ε — Erro aleatório (resíduo ou ruído)

O termo ε representa tudo aquilo que afeta Y , mas não está explicitamente modelado por X .

Inclui: variáveis omitidas, erro de medição, variabilidade natural do processo.

O ruído não é falha do modelo — ele é parte do fenômeno.

Sinal e ruído

Ao observar dados empíricos, sempre lidamos com duas componentes distintas:

- **Sinal**

Representa a relação sistemática entre X e Y, isto é, o **comportamento médio esperado** da variável resposta para cada valor da variável explicativa.

- **Ruído**

Representa as variações aleatórias em torno desse comportamento médio, causadas por fatores não observados, erros de medição e flutuações naturais do processo.

A regressão linear simples busca **capturar o sinal**, aceitando explicitamente que o ruído **sempre existirá**.

SINAL - O que estamos vendo?

Pontos → dados observados


Incluem o efeito da relação real +
ruído aleatório

Linha tracejada → *sinal verdadeiro (conceitual)*

Relação sistemática entre X e Y
Não observável diretamente no
mundo real

Linha contínua → *sinal estimado pela regressão*

Melhor aproximação possível do
padrão médio, dado o ruído



RUÍDO - O que estamos vendo?

Pontos: Valores observados de Y para cada valor de X

Reta:

Valor médio estimado de Y dado X

$$\rightarrow \hat{Y} = \beta_0 + \beta_1 X$$


(o sinal estimado)

Linhas verticais pontilhadas

Representam o **ruído (ϵ)** ou, na prática, os **resíduos**:

$$\epsilon = Y - \hat{Y}$$

Representação visual do ruído (ϵ) na regressão linear simples



Como a reta de regressão é estimada?

A reta da regressão linear simples é estimada pelo **método dos mínimos quadrados ordinários (MQO)**.

Esse método escolhe os coeficientes β_0 e β_1 de forma que a reta **minimize a soma dos quadrados dos resíduos**.

O que isso significa, na prática?

Para cada observação, existe um **resíduo**: $e_i = y_i - \hat{y}_i$

onde: $\hat{y}_i = \beta_0 + \beta_1 x_i$

O MQO escolhe β_0 e β_1 que minimizam:

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \bar{y}_i)^2$$

Por que elevar ao quadrado?

- evita cancelamento de erros positivos e negativos;
- penaliza erros grandes mais fortemente;
- garante uma solução matemática única.

Método dos mínimos quadrados ordinários (MQO)

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x}$$

Essas fórmulas mostram que:

- a inclinação depende da **covariância entre X e Y**;
- o intercepto ajusta a reta ao centro dos dados.



PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.



Regressão Linear Simples



Exemplo - Tecnologia

Um time de SRE/Observabilidade está monitorando um serviço e quer entender como o **uso médio de CPU (%)** se relaciona com o **tempo médio de resposta (ms)** em janelas de tempo (por exemplo, 5 minutos).

A ideia é verificar se existe uma **tendência linear média**: à medida que o uso médio da CPU aumenta, o tempo de resposta tende a crescer.

X (contínua): uso médio de CPU (%)

Y (contínua): tempo médio de resposta (ms)

n = 60 janelas (amostra para análise)

Arquivo: exemplo_regressao_CPU_tempo_resposta.csv

Exemplo - Tecnologia

Variáveis do estudo

Variável explicativa (X): Uso médio de CPU (%)

Representa o nível de carga do serviço.

Variável resposta (Y): Tempo médio de resposta (ms)

Representa a performance percebida pelo usuário.

Ambas são **variáveis contínuas**, adequadas para regressão linear.


Exemplo - Tecnologia

Exploração inicial dos dados

Antes de qualquer modelo, o analista deve **olhar os dados**.

O **diagrama de dispersão** ajuda a responder:

- Existe tendência crescente ou decrescente?
- A relação parece aproximadamente linear?
- Existem pontos claramente discrepantes?



**Regressão não começa pela equação.
Começa pela visualização.**

Exemplo - Tecnologia

Associação linear: correlação de Pearson

Após a visualização, avaliamos a **associação linear** entre CPU e tempo de resposta.

--- Correlação de Pearson (exploração inicial) ---

$r = 0.858165 \rightarrow$ Associação linear positiva forte

$p\text{-valor} = 1.938047e-18 \rightarrow$ Há **evidência estatística** de associação linear entre CPU e tempo de resposta

A correlação mede força e direção, mas não fornece uma equação de estimativa.

Exemplo - Tecnologia

Por que não parar na correlação?

Apesar de útil, a correlação tem limitações importantes:

- Não permite estimar valores de Y a partir de X;
- Não fornece interpretação em unidades do problema (ms por %CPU);
- Não separa explicitamente **signal** e **ruído**.

Para isso, precisamos de um **modelo de regressão**.

Exemplo - Tecnologia

Ajuste do modelo de regressão linear simples

O modelo ajustado é:

$$\hat{y} = 50,7807 + 2,3197x$$

Onde:

$\hat{\beta}_0$: intercepto $\rightarrow 50,7807$

$\hat{\beta}_1$: inclinação $\rightarrow 2,3197$

Os parâmetros são estimados pelo **método dos mínimos quadrados ordinários (MQO)**.

=====	
	coef

const	50.7807
CPU_medio_pct	2.3197
=====	

Exemplo - Tecnologia

O modelo ajustado é:

$$\hat{y} = 50,7807 + 2,3197x$$

$$\text{Se } x = 50 \rightarrow \hat{y} = 166,7657$$

$$\text{Se } x = 51 \rightarrow \hat{y} = 169,0854$$

↑ 1 unidade em x → ↑ 2,3197 unidades em y

Interpretação do coeficiente β_1

O coeficiente β_1 responde à pergunta:

Em média, quanto o tempo de resposta aumenta quando o uso de CPU cresce 1 ponto percentual?

Exemplo de leitura:

$$\hat{\beta}_1 = 2,3197$$

→ cada **+1% no uso médio da CPU** está associado a um aumento médio de **2,32 ms** no tempo de resposta.

Interpretação sempre média e condicional ao intervalo observado.

Exemplo - Tecnologia

O modelo ajustado é:

$$\hat{y} = 50,7807 + 2,3197x$$

$$\text{Se } x=0 \rightarrow \hat{y} = 50,7807$$

Interpretação do coeficiente β_0

No modelo de regressão linear simples, o intercepto β_0 representa:

o valor médio estimado da variável resposta quando a variável explicativa assume valor zero.

Exemplo de leitura:

$$\hat{\beta}_0 = 50,7807$$

Quando o uso de CPU é 0%, o tempo médio de resposta estimado é de 50,78ms.

Exemplo - Tecnologia

Mas... CPU = 0% faz sentido?
Nem sempre!

Em sistemas reais: CPU raramente é 0%; o serviço pode nem estar ativo nesse ponto.

Logo, **neste contexto**, o intercepto deve ser entendido como:

- um **baseline matemático** do modelo;
- necessário para posicionar corretamente a reta;
- não necessariamente interpretável como situação real observável.

Portanto, nem todo intercepto possui interpretação operacional direta.

Exemplo - Tecnologia

Valores estimados

Para cada observação (x_i, y_i) , o modelo ajustado produz:

Valor estimado (predição média)

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Interpretação:

$\hat{y}_i$ é o **valor esperado (médio)** de y_i para aquele valor de x_i .

É uma estimativa média (tendência), não uma previsão perfeita do ponto individual.

Exemplo - Tecnologia

**Valores estimados
calculados à partir da reta
de regressão estimada:**

$$\hat{y}_i = 50,7807 + 2,3191x_i$$

Por exemplo, $x=50,68 \rightarrow$

$$\hat{y}_i = 168,34$$

--- Tabela ilustrativa (15 primeiros registros) ---

Janela	CPU_medio_pct	Tempo_resposta_ms	Y_estimado	Residuo
1	50.68	179.33	168.340854	10.989146
2	41.07	138.25	146.048961	-7.798961
3	58.12	188.35	185.599095	2.750905
4	54.87	178.87	178.060213	0.809787
5	69.50	191.41	211.996780	-20.586780
6	57.98	172.28	185.274343	-12.994343
7	46.70	169.76	159.108624	10.651376
8	39.04	132.26	141.340059	-9.080059
9	61.13	196.49	192.581259	3.908741
10	51.82	170.54	170.985262	-0.445262
11	54.26	169.73	176.645223	-6.915223
12	48.91	164.78	164.235063	0.544937
13	35.00	139.64	131.968649	7.671351
14	64.08	195.88	199.424244	-3.544244
15	59.83	188.94	189.565706	-0.625706

Exemplo - Tecnologia

Resíduos

$$e_i = y_i - \hat{y}_i$$

Interpretação:

O resíduo mede quanto a observação real (y_i) ficou:

- **acima** do valor esperado ($e_i > 0$) ou
- **abaixo** do valor esperado ($e_i < 0$).

Exemplo - Tecnologia

Resíduos calculados à partir da reta de regressão estimada:

$$e_i = y_i - \hat{y}_i$$

Por exemplo,

$x=50,68 \rightarrow y=179,33 \rightarrow$

$\hat{y}_i = 168,34 \rightarrow e_i = 10,99$

--- Tabela ilustrativa (15 primeiros registros) ---

Janela	CPU_medio_pct	Tempo_resposta_ms	Y_estimado	Residuo
1	50.68	179.33	168.340854	10.989146
2	41.07	138.25	146.048961	-7.798961
3	58.12	188.35	185.599095	2.750905
4	54.87	178.87	178.060213	0.809787
5	69.50	191.41	211.996780	-20.586780
6	57.98	172.28	185.274343	-12.994343
7	46.70	169.76	159.108624	10.651376
8	39.04	132.26	141.340059	-9.080059
9	61.13	196.49	192.581259	3.908741
10	51.82	170.54	170.985262	-0.445262
11	54.26	169.73	176.645223	-6.915223
12	48.91	164.78	164.235063	0.544937
13	35.00	139.64	131.968649	7.671351
14	64.08	195.88	199.424244	-3.544244
15	59.83	188.94	189.565706	-0.625706

Por que os resíduos são fundamentais?

Os resíduos são a **principal ferramenta de diagnóstico** da regressão linear, pois eles:

- **Revelam padrões não capturados pelo modelo** (curvaturas, efeitos omitidos, má especificação);
- **Permitem avaliar se a relação média é realmente linear;**
- **Ajudam a identificar outliers e pontos influentes;**
- **Indicam possíveis violações das suposições do modelo.**



PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.



Regressão Linear Simples



Testes de hipóteses para os coeficientes

Após estimar o modelo de regressão, podemos avaliar **se os coeficientes estimados são estatisticamente diferentes de zero**, ou seja, se existe evidência de relação linear na população.

Teste de hipóteses para o coeficiente angular (β_1)

Hipóteses estatísticas

Testamos:

Hipótese nula (H_0) $\rightarrow H_0: \beta_1 = 0$

Não existe **efeito linear médio** de X sobre Y.

Em média, variações em X **não estão associadas** a variações em Y.

Hipótese alternativa (H_1) $\rightarrow H_1: \beta_1 \neq 0$

Existe um **efeito linear médio diferente de zero**.

Em média, mudanças em X estão associadas a mudanças sistemáticas em Y.

Teste de hipóteses para o coeficiente angular (β_1)

Estatística de teste

$$t = \frac{\hat{\beta}_1 - 0}{EP(\hat{\beta}_1)}$$

onde:

$\hat{\beta}_1$ é o coeficiente estimado;

$EP(\hat{\beta}_1)$ é o erro-padrão do estimador.

Teste de hipóteses para o coeficiente angular (β_1)

Interpretação do p-valor

$\text{p-valor} \leq \alpha \rightarrow \text{Rejeita-se } H_0$

$\text{p-valor} > \alpha \rightarrow \text{Não rejeita-se } H_0$

Pergunta a ser respondida:

Há (ou não) evidência estatística de efeito linear médio de X sobre Y?

Teste de hipóteses para o coeficiente angular (β_1)

Nível de significância (α)

α representa o **nível de significância do teste**, isto é, a probabilidade máxima de rejeitar H_0 quando ela é verdadeira.

Valores comumente utilizados:

$\alpha = 5\%$ (padrão mais frequente);

$\alpha = 1\%$ (mais conservador);

$\alpha = 10\%$ (mais permissivo).

O valor **não é fixo** e deve ser definido **antes da análise**, de acordo com: custo de erros; contexto do problema; objetivo do estudo.

Teste de hipóteses para o coeficiente angular (β_1)

Exemplo: CPU x Tempo de resposta

	coef	std err	t	P> t	[0.025	0.975]
const	50.7807	10.094	5.031	0.000	30.576	70.985
CPU_medio_pct	2.3197	0.182	12.731	0.000	1.955	2.684

Valor $p = 0,000 < 0,05 \rightarrow$ Rejeitamos H_0

Teste de hipóteses para o coeficiente angular (β_1)

Exemplo: CPU x Tempo de resposta

β_1 significativo $\rightarrow$ CPU é um **fator relevante** para o tempo médio de resposta;
 β_1 não significativo $\rightarrow$ CPU **não explica**, sozinha, a variação média no tempo de resposta.

Isso afeta decisões como:

- otimizar CPU ou não;
- buscar outras variáveis explicativas;
- repensar o modelo.

Isso orienta a **próxima etapa da análise**, não encerra o estudo.

Coeficiente de Determinação (R^2) – O que é?

O coeficiente de determinação mede:

a proporção da variabilidade total de Y que é explicada pelo modelo de regressão.

Formalmente:

$$R^2 = \frac{\text{Variabilidade explicada pelo modelo}}{\text{Variabilidade total de Y}}$$

Coeficiente de Determinação (R^2) – O que é?

Ou, em termos de somas de quadrados:

$$R^2 = 1 - \frac{SQ_{Res}}{SQ_{Total}}$$

onde:

SQ_{Total} : variabilidade total de Y em torno da média;

SQ_{Res} : variabilidade não explicada (resíduos).

R^2 varia entre **0 e 1**.

Coeficiente de Determinação (R^2) – Interpretação prática

Exemplos de leitura:

$$R^2 = 0,20$$

→ 20% da variabilidade de Y é explicada por X

→ 80% permanece nos resíduos

$$R^2 = 0,75$$

→ 75% da variabilidade de Y é explicada pelo modelo

Interpretação correta:

O R^2 fala sobre variabilidade, não sobre erro médio, nem sobre precisão individual.

Coeficiente de Determinação (R^2) – Interpretação prática

Exemplo: CPU x Tempo de resposta

```
=====
                        OLS Regression Results
=====
Dep. Variable:          Tempo_resposta_ms      R-squared:                0.736
Model:                  OLS                   Adj. R-squared:           0.732
Method:                 Least Squares         F-statistic:             162.1
Date:                  Fri, 30 Jan 2026       Prob (F-statistic):      1.94e-18
Time:                  12:07:23              Log-Likelihood:         -249.33
No. Observations:      60                   AIC:                    502.7
Df Residuals:          58                   BIC:                    506.9
Df Model:              1
Covariance Type:       nonrobust
=====
```

Aproximadamente **73,6%** da variabilidade observada no tempo médio de resposta é explicada pelo modelo de regressão linear que utiliza o uso médio da CPU como variável explicativa.

Coeficiente de Determinação (R^2) – O que R^2 NÃO mede

Um R^2 alto **não garante** que:

- o modelo esteja corretamente especificado
- a relação seja realmente linear
- exista causalidade
- as previsões individuais sejam boas
- não existam padrões nos resíduos

Um modelo pode ter R^2 alto e ainda assim ser **estatisticamente inadequado**.

Por isso: **R^2 nunca substitui análise de resíduos.**

Coeficiente de Determinação (R^2) – Como usar R^2 de forma correta

Use R^2 para:

- comparar explicação da variabilidade entre modelos com mesma variável resposta
- avaliar se X tem potencial explicativo relevante
- comunicar, de forma simples, quanto do comportamento de Y está sendo explicado

Coeficiente de Determinação (R^2) – Como usar R^2 de forma correta

Mas nunca use R^2 isoladamente.

Avaliação completa de regressão inclui:

- análise de resíduos;
- testes de hipóteses;
- interpretação dos coeficientes;
- coerência com o contexto do problema.



PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.



Regressão Linear Simples



O que são resíduos?

Em regressão linear, **o resíduo mede a parte da observação que não foi explicada pelo modelo.**

Para cada observação i :

$$e_i = y_i - \hat{y}_i$$

onde:

y_i :valor observado;

$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$:valor estimado pelo modelo.

Os resíduos representam **o ruído do sistema** não capturado pela relação média.

O que são resíduos padronizados?

Os **resíduos padronizados** ajustam os resíduos pela sua variabilidade esperada:

$$r_i = \frac{e_i}{\hat{\sigma}}$$

onde:

e_i :resíduo bruto;

$\hat{\sigma}$:desvio-padrão estimado dos erros;

Assim, os resíduos ficam em **unidades de desvio-padrão**.

Interpretação dos resíduos padronizados

Como estão em escala padronizada:

$r_i \approx 0 \rightarrow$ comportamento esperado;

$|r_i| > 2 \rightarrow$ possível outlier;

$|r_i| > 3 \rightarrow$ forte evidência de observação atípica.

Essas são regras práticas, não critérios absolutos.

Resíduos vs Resíduos Padronizados

Aspecto	Resíduo (bruto) (e_i)	Resíduo Padronizado (r_i)
Definição	Diferença entre valor observado e valor estimado	Resíduo ajustado pela variabilidade esperada
Unidade	Mesma unidade de Y (ms, R\$, etc.)	Unidade adimensional (desvios-padrão)
Comparabilidade	Difícil comparar entre observações	Comparáveis entre si
Uso principal	Visualização inicial e intuição do erro	Diagnóstico formal e detecção de outliers
Detecção de outliers	Limitada	Possui regras práticas
Dependência da escala	Sim	Não

Distância de Cook – O que é?

A Distância de Cook mede:

Quanto os coeficientes da regressão mudariam se uma observação fosse removida.

Ou seja, ela combina:

- tamanho do resíduo, e
- posição do ponto no espaço de X (alavancagem).

É uma medida global de impacto da observação no modelo.

Intuição por trás da Distância de Cook

Uma observação é influente quando:

- tem erro relativamente grande, **e/ou**
- está em região extrema de X (alta alavancagem).

Mesmo um erro pequeno pode ser perigoso se:

- o ponto estiver isolado em X,
- e “puxar” a inclinação da reta.

A Distância de Cook detecta exatamente esse tipo de situação.

Como interpretar a Distância de Cook?

Regra prática mais comum:

Uma observação é potencialmente influente se:

$$D_i > \frac{4}{n}$$


onde **n** é o tamanho da amostra.

Outras regras usadas:


$D_i > 1 \rightarrow$ influência muito forte (mais raro)

Não é critério de exclusão automática, é critério de investigação.

Visualização: gráfico da Distância de Cook



Exemplo: CPU x tempo de resposta



Exemplo: CPU x tempo de resposta

Distância de Cook:

```
--- Distância de Cook (limite prático: 4/n = 0.066667) ---
índice  CPU_medio_pct  Tempo_resposta_ms  cook_d
    28         82.30         276.09 0.382159
    23         27.75         138.40 0.154743
    24         71.75         185.73 0.131074
    48         56.86         228.36 0.077094
    53         32.88         108.00 0.067873
```

Isso indica que **essas observações exercem influência relevante** na reta ajustada.

Exemplo: CPU x tempo de resposta

Distância de Cook:

Se removermos uma dessas observações, a inclinação β_1 pode mudar perceptivelmente.

Isso levanta perguntas analíticas:

- o comportamento médio é realmente linear?
- o efeito da CPU cresce mais rápido em níveis altos?
- há regimes diferentes de operação?

O que fazer quando um ponto é influente?

Primeiro: investigar

- Erro de medição?
- Registro incorreto?
- Observação válida, mas rara?

Depois: decidir

- Ajustar modelos com e sem o ponto (análise de sensibilidade);
- Modelar subgrupos separadamente;
- Usar métodos robustos;
- Manter o ponto, se ele representa o fenômeno real.

Remover ponto sem justificativa é erro metodológico.



PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.



Regressão Linear Simples



Premissas do modelo de regressão linear

O modelo de regressão linear simples não é apenas uma equação, ele depende de **suposições sobre o comportamento dos erros**.

Essas premissas garantem que:

- estimativas sejam não viesadas;
- erros-padrão sejam corretos;
- testes de hipóteses e p-valores sejam válidos;
- intervalos de confiança tenham cobertura adequada.

Sem essas premissas, o modelo ainda pode gerar uma reta, mas **a inferência estatística pode estar errada**.

Suposições do Modelo de Regressão Linear

Para que os resultados da regressão linear sejam **estatisticamente válidos**, assumimos:

- O relacionamento entre y e x é linear, ou ao menos bem aproximado por uma linha reta na região considerada do estudo.
- Os resíduos têm média zero.
- Os resíduos têm variância constante σ^2 .
- Os resíduos não são correlacionados.
- Os resíduos têm distribuição normal.
- Ausência de outliers nos resíduos

Essas suposições garantem que **erros-padrão, testes de hipóteses e intervalos de confiança sejam confiáveis**.

Suposição: Linearidade

A relação média entre X e Y é linear.

Essa suposição é avaliada principalmente por meio de **gráficos**, não por testes formais.

Onde observar a linearidade?


- Gráfico de dispersão (Y vs X)
- Gráfico de resíduos vs X
- Gráfico de resíduos vs valores estimados

O gráfico de resíduos é o mais sensível para diagnóstico.


Quando é violada? Relações curvas (quadrática, exponencial, logarítmica).

Suposição: Linearidade

(a) Linearidade — OK



(b) Violação de linearidade



Suposição: Homocedasticidade

O que significa?

A variância dos resíduos é aproximadamente constante para todos os valores de X .

Violação típica:



Formato de funil, cone (variância crescente ou decrescente).

Diagnóstico inicial:

Gráfico de Resíduos vs X ;

Gráfico de Resíduos vs valores estimados.


Suposição: Homocedasticidade



Suposição: Homocedasticidade

Exemplo: CPU x tempo de resposta

Os resíduos estão **distribuídos de forma relativamente uniforme** ao longo dos valores de CPU;
Não há evidência visual clara de **aumento ou redução progressiva da variância**;
A suposição de **homocedasticidade parece razoável** para esse modelo.



Suposição: Homocedasticidade

Existem testes formais para homocedasticidade?

Sim. Os mais usados são:

- **Teste de Breusch–Pagan**
- **Teste de White**

Ambos testam:

H_0 : *variância constante (homocedasticidade)*

H_1 : *variância depende de X (heterocedasticidade)*

Interpretação

$p\text{-valor} \leq \alpha \rightarrow$ evidência de heterocedasticidade

$p\text{-valor} > \alpha \rightarrow$ evidência de homocedasticidade

1° Gráfico $\rightarrow$ entendimento do problema
2° Teste $\rightarrow$ apoio formal à decisão
Nunca o contrário!

Suposição: Homocedasticidade

Teste de Breusch–Pagan: Exemplo da CPU x Tempo de resposta

```
--- Teste de Breusch-Pagan (heterocedasticidade) ---  
Estatística LM  = 0.627487  
p-valor (LM)   = 0.428279  
Estatística F   = 0.612981  
p-valor (F)    = 0.436853  
Conclusão: não há evidência de heterocedasticidade (não rejeita  $H_0$ ).
```

O teste de Breusch–Pagan pode ser expresso por duas estatísticas:

LM (qui-quadrado) — forma clássica do teste

F — forma alternativa baseada em regressão auxiliar

Ambas testam a mesma hipótese. Em prática, a decisão costuma ser baseada no p-valor da estatística LM.

Suposição: Independência

O que significa?

O erro de uma observação não influencia o erro de outra.

Onde é comum violar?

- Séries temporais;
- Dados espaciais;
- Dados longitudinais.

Quais são as consequências?

- Erros-padrão incorretos;
- Testes t e p-valores inválidos.

Suposição: Independência

Como diagnosticar a independência dos resíduos?

Gráfico dos resíduos ao longo do tempo.

Padrão desejado:


- flutuações aleatórias,
- sem ciclos,
- sem tendência.

Violação:

- ondas,
- sequências de sinais positivos ou negativos,
- padrões repetitivos.


Suposição: Independência

(a) Independência — OK




- Troca de sinal frequente
- Sem blocos longos
- Hoje não depende de ontem

(b) Autocorrelação — Violação



- Blocos persistentes
- Mudanças suaves
- Hoje se parece com ontem

Independência: Exemplo (CPU x tempo)



Independência: Exemplo (CPU x tempo)

Observações importantes:

- Os resíduos oscilam em torno de zero, sem tendência crescente ou decrescente;
- Há alternância frequente entre valores positivos e negativos;
- Não se observa um padrão claro de **ondas persistentes**;
- Existem picos isolados (resíduos grandes), mas **não em sequência prolongada**.

Esses comportamentos são **compatíveis com ausência de autocorrelação forte**.

Suposição: Independência

Teste formal de autocorrelação: Durbin–Watson

O teste de Durbin–Watson detecta apenas **autocorrelação de primeira ordem** (entre resíduos consecutivos).

Outros padrões temporais podem não ser detectados.

Hipóteses:

H_0 : *resíduos não são autocorrelacionados* (São independentes)

H_1 : *resíduos são autocorrelacionados* (Não são independentes)

Estatística de teste:

$$DW = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2}$$

Suposição: Independência

Teste formal de autocorrelação: Durbin–Watson

Interpretação **aproximada**:

$DW \approx 2 \rightarrow$ sem autocorrelação $\rightarrow$ Independência

$DW < 2 \rightarrow$ autocorrelação positiva

$DW > 2 \rightarrow$ autocorrelação negativa

É um teste específico, não detecta padrões complexos.

Suposição: Independência

Teste formal de autocorrelação: Teste de Breusch–Godfrey

O teste de Breusch–Godfrey (BG) é um teste formal para **autocorrelação serial** nos erros.

O que ele testa?

Se os resíduos apresentam autocorrelação até uma ordem p (ex.: 1, 2, 3...).

Por que ele é preferido?

- Funciona para regressão simples e múltipla;
- Permite testar **ordens maiores**;
- Fornece **p-valor** (sem tabela crítica e sem regiões inconclusivas).

Suposição: Independência

Teste formal de autocorrelação: Teste de Breusch–Godfrey

Hipóteses do teste:

Para uma ordem p :

$$H_0: \rho_1 = \rho_2 = \dots = \rho_p = 0$$

$$H_1: \text{pelo menos um } \rho_j \neq 0$$

Em palavras:

H_0 : não há autocorrelação serial nos erros até a ordem $p \rightarrow$ **resíduos independentes no tempo**

H_1 : existe autocorrelação serial $\rightarrow$ resíduos não são independentes no tempo

Suposição: Independência

Teste formal de autocorrelação: Teste de Breusch–Godfrey

Escolha um nível de significância α , por exemplo, 5%, mas pode ser 1% ou 10%.

Se **p-valor** $\leq \alpha \rightarrow$ rejeita $H_0 \rightarrow$ há evidência de autocorrelação

Se **p-valor** $> \alpha \rightarrow$ não rejeita $H_0 \rightarrow$ sem evidência de autocorrelação

O Durbin–Watson dá um termômetro rápido; o Breusch–Godfrey dá o teste formal com p-valor.

Suposição: Independência

Exemplo: CPU x tempo de resposta

--- Durbin-Watson (autocorrelação de 1ª ordem) – diagnóstico ---

DW = 2.412156

Direção sugerida: autocorrelação negativa.

Leitura rápida: fraca ou inexistente (DW próximo de 2).

Obs.: Para decisão formal, use Breusch-Godfrey (abaixo).

--- Teste de Breusch-Godfrey (autocorrelação até ordem 1) ---

H0: resíduos NÃO apresentam autocorrelação serial até a ordem testada.

H1: resíduos apresentam autocorrelação serial (existe dependência temporal).

Estatística LM = 2.667427

p-valor (LM) = 1.024215e-01

Estatística F = 2.651954

p-valor (F) = 1.089380e-01

Conclusão ($\alpha=0.05$): não há evidência de autocorrelação (não rejeita H0).

$0,102 > 0,05 \rightarrow$ não rejeita $H_0 \rightarrow$ sem evidência de autocorrelação!

Suposição: Normalidade

O que significa?

Os erros seguem distribuição aproximadamente normal.

Importância:

Ela é importante principalmente para:

- validade dos **testes t** dos coeficientes;
- construção correta de **intervalos de confiança**;
- inferência em **amostras pequenas**.

Para estimar a reta, a normalidade não é necessária.

Ela afeta a inferência, não o ajuste geométrico.

Suposição: Normalidade

Avaliação gráfica: o método mais informativo

A principal ferramenta é o **QQ-plot dos resíduos**.


Como interpretar?

- Pontos próximos da reta → normalidade plausível
- Desvios nas caudas → caudas pesadas ou assimetria
- Curvatura em S → distribuição não normal

O QQ-plot mostra **onde** a normalidade falha, não só se falha.


Suposição: Normalidade

(a) Normalidade — OK
QQ-plot dos resíduos padronizados



- Pontos próximos da reta
- Caudas compatíveis
- Inferência confiável

(b) Violação de normalidade
Caudas pesadas



- Desvios nas caudas
- Outliers prováveis
- p-valores frágeis

Suposição: Normalidade

Testes formais de normalidade:

Os mais usados são:

- **Shapiro–Wilk**

Mais comum e mais potente em n pequeno.

- **Kolmogorov–Smirnov**

Só deve ser realizado quando não há observações empatadas.

- **Anderson–Darling**

É mais poderoso para amostras maiores que 50.

Suposição: Normalidade

Testes formais de normalidade:

Hipóteses estatísticas:

H_0 : Os resíduos seguem a distribuição Normal

H_1 : Os resíduos não seguem a distribuição Normal

Interpretação:

$p\text{-valor} \leq \alpha \rightarrow$ Não há normalidade nos resíduos.

$p\text{-valor} > \alpha \rightarrow$ Há normalidade nos resíduos.

Para o teste de Anderson-Darling, a regra de decisão é:

$A^2 > \text{valor crítico}(\alpha) \rightarrow \text{rejeita } H_0 \rightarrow$ Não há normalidade nos resíduos.

Normalidade: Exemplo CPU xTempo

--- Teste de Shapiro-Wilk (normalidade dos resíduos) ---

Estatística W = 0.982026

p-valor = 5.199824e-01

Conclusão: normalidade dos resíduos é plausível (não rejeita H_0).

--- Teste de Anderson-Darling (normalidade dos resíduos) ---

Estatística A^2 = 0.280205

Valores críticos:

$\alpha = 15.0\%$ | valor crítico = 0.544000

$\alpha = 10.0\%$ | valor crítico = 0.619000

$\alpha = 5.0\%$ | valor crítico = 0.743000


$\alpha = 2.5\%$ | valor crítico = 0.866000

$\alpha = 1.0\%$ | valor crítico = 1.030000

Decisão para $\alpha = 5.0\%$:

Conclusão: normalidade dos resíduos é plausível (não rejeita H_0).

QQ-plot dos resíduos padronizados — checar normalidade





PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.



Regressão Linear Simples



Para pensar:

Quando os resíduos violam alguma
suposição do modelo,
o que fazer?

Se a linearidade for violada

Possíveis soluções:

- Transformar X (log, raiz, etc.);
- Incluir termos polinomiais (X^2 , X^3);
- Usar modelos não lineares;
- Segmentar o modelo (regimes diferentes).

Forçar reta em relação curva gera inferência enganosa.

Se houver heterocedasticidade

Possíveis soluções:

- Transformar a variável resposta (logaritmo, transformação de Box–Cox);
- Utilizar **Mínimos Quadrados Generalizados (GLS)** ou **Mínimos Quadrados Ponderados (WLS)**, modelando explicitamente a variância dos erros.

Observação importante:

Os coeficientes da regressão podem permanecer não viesados, mas os erros-padrão, p-valores e intervalos de confiança ficam incorretos.

Se houver autocorrelação dos resíduos

Possíveis soluções:

- Incluir **variáveis defasadas** no modelo;
- Ajustar regressão com **erros autorregressivos (AR)**;
- Utilizar **modelos de séries temporais** como modelos autorregressivos integrados de médias móveis (ARIMA);
- Usar **modelos mistos** quando há dependência estrutural.

Indica que o sistema possui memória temporal.

Se os resíduos não forem normalmente distribuídos

Possíveis soluções:

- Transformar a variável resposta;
- Utilizar **reamostragem por bootstrap** para inferência;
- Aplicar **métodos robustos à não normalidade**;
- Investigar observações influentes e reespecificar o modelo.

A normalidade afeta principalmente os testes estatísticos, não a reta ajustada.

Se houver outliers ou pontos influentes

Possíveis ações:


- Verificar possível erro de coleta ou digitação;
- Avaliar se há **subgrupos distintos** na população;
- Ajustar modelos com e sem a observação para análise de sensibilidade;
- Nunca remover observações sem justificativa técnica.

Outlier pode ser erro — ou informação valiosa.

Processo iterativo de modelagem

- 1 Ajustar modelo inicial
- 2 Analisar resíduos
- 3 Identificar violações
- 4 Escolher estratégia corretiva
- 5 Reajustar o modelo
- 6 Reavaliar os resíduos

Modelagem é um processo iterativo, não uma etapa única.



Bons modelos não nascem prontos.

Eles são construídos a partir dos erros do modelo anterior.



PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.