

Disciplina:

MACHINE LEARNING







Professor: Rafael Barroso



APRESENTAÇÃO




BIBLIOGRAFIA




TÓPICO 1

INTRODUÇÃO AO ML: DEFINIÇÕES, TIPOS DE APRENDIZADO E PARADIGMAS




O QUE É APRENDIZADO DE MÁQUINA?

- **Inteligência Artificial (IA):** O universo completo. A ideia de máquinas inteligentes. É a capacidade de uma máquina de simular o comportamento humano inteligente (raciocinar, resolver problemas).
- **Machine Learning (ML):** Uma parte da IA. Máquinas que aprendem com dados. Ou seja, algoritmos que aprendem padrões a partir de dados, sem serem programados para cada regra.
- **Deep Learning (DL):** Uma técnica de ML. Aprendizado profundo com redes neurais. Faz uso de Redes Neurais Artificiais com muitas camadas, simulando a estrutura e funcionamento do cérebro humano



Source: Data Iku

O QUE É APRENDIZADO DE MÁQUINA?



O QUE É APRENDIZADO DE MÁQUINA?

PREDIÇÃO E INFERÊNCIA


▪ PREDIÇÃO:

- Foco no resultado obtido a partir de um conjunto de dados;
- Logo, busca-se diminuir ao máximo o erro redutível das estimativas;
- O erro irreduzível é intrínseco e não se altera;
- São modelos comumente conhecidos como caixas-pretas.

▪ INFERÊNCIA:

- Usados quando o objetivo maior não é necessariamente prever um valor y ;
- Busca-se responder questões como: “quais preditores melhor se associam à resposta?”, “qual a relação entre preditores e resposta?” e “a relação entre o preditor e a resposta pode ser simplificada por uma equação linear ou demanda uma abordagem mais complexa?”

E O QUE É CIÊNCIA DE DADOS?



TIPOS DE APRENDIZADO DE MÁQUINA


SUPERVISIONADO

NÃO-SUPERVISIONADO

TIPOS DE APRENDIZADO

APRENDIZADO SUPERVISIONADO:

- É aquele em que os **dados de treinamento são rotulados**, o que significa que cada observação é associada a uma saída esperada.
- O objetivo é construir um modelo que possa aprender a associar dados de entrada a saídas correspondentes.
- Dois tipos:
 - **Classificação:** o objetivo é prever uma classe, que é uma escolha dentro de uma lista predefinida de possibilidades.
 - **Regressão:** o objetivo é prever um número contínuo (do tipo número de ponto flutuante).



TIPOS DE APRENDIZADO


APRENDIZADO SUPERVISIONADO:

■ CLASSIFICAÇÃO:



- Ex.: classificar íris em uma das três espécies possíveis: setosa, versicolor ou virginica.
- Classificação binária: distinguir entre exatamente duas classes. Por exemplo, classificar e-mails como spam ou não spam.
- Classificação multiclasse: classificação entre mais de duas classes. Por exemplo, prever o idioma de um site a partir do texto apresentado.

■ REGRESSÃO:

- Ex.: prever a renda anual de uma pessoa com base na educação, idade e local de residência.
- Ex.: prever a produção de uma fazenda de milho com base em rendimentos anteriores, clima e número de funcionários trabalhando na fazenda.
- Ex.: prever a os custos hospitalares que serão necessários com base nos exames e sintomas do paciente.




TIPOS DE APRENDIZADO



TIPOS DE APRENDIZADO

APRENDIZADO NÃO-SUPERVISIONADO:


- É aquele em que os **dados de treinamento não apresentam rótulos**, o que significa que cada observação não está associada uma saída esperada.
- Dois tipos:
 - **Transformações Não-Supervisionadas:** são algoritmos que criam uma nova representação dos dados que pode ser mais fácil para humanos ou outros algoritmos entenderem como é a representação original dos dados.
 - **Algoritmos de Agrupamento:** dividem os dados em grupos distintos de itens semelhantes.



TIPOS DE APRENDIZADO

APRENDIZADO NÃO-SUPERVISIONADO – EXEMPLOS:

- **Redução de dimensionalidade:** busca reduzir o número de recursos em um conjunto de dados. Isso pode ser útil para melhorar a eficiência de modelos e para facilitar a visualização dos dados.
- **Extração de tópicos:** é um tipo de transformação que identifica os tópicos em um conjunto de dados de texto. Isso pode ser útil para classificar documentos, para organizar dados ou para gerar resumos.
- **Agrupamento:** é um tipo de algoritmo que divide os dados em grupos distintos de itens semelhantes. Isso pode ser útil para identificar padrões nos dados, para segmentar clientes ou para agrupar produtos.



TIPOS DE APRENDIZADO


APRENDIZADO NÃO-SUPERVISIONADO:

▪ VANTAGENS:



- Pode ser usado para aprender sobre os dados sem ter conhecimento prévio sobre eles. Isso pode ser útil em situações em que os dados são novos ou complexos.
- Utilização na identificação de padrões que não seriam aparentes com a visão humana.
- Criação de novas informações a partir dos dados originais.

▪ DESVANTAGENS:

- Pode ser mais complexa na implementação e avaliação.
- Tende a ser menos preciso que o aprendizado supervisionado.



TIPOS DE APRENDIZADO



Fonte: <https://nicola17.github.io/tfjs-tsne-demo/>

TIPOS DE APRENDIZADO

APRENDIZADO POR REFORÇO – EXEMPLOS:

- **Jogos e simulações:** é o treinamento de agentes para tomar decisões e maximizar pontuações em ambientes virtuais, como xadrez, Go ou videogames. Isso pode ser útil para desenvolver inteligências artificiais capazes de criar estratégias complexas e até superar o desempenho humano.
- **Robótica:** busca ensinar máquinas a realizar tarefas físicas por meio de tentativa e erro, como caminhar, desviar de obstáculos ou manipular objetos. Isso pode ser útil para a automação industrial, veículos autônomos ou para exploração de ambientes hostis.
- **Otimização de sistemas:** é um modelo aplicado para tomar sequências de decisões em processos dinâmicos. Isso pode ser útil para gerenciar rotas de tráfego, otimizar o consumo de energia em data centers ou melhorar sistemas de recomendação contínua de conteúdo.

TIPOS DE APRENDIZADO

APRENDIZADO POR REFORÇO:

■ VANTAGENS:


- Pode resolver problemas complexos onde a resposta "certa" não é conhecida previamente, aprendendo apenas pela interação contínua com o ambiente.
- Possui capacidade de descobrir soluções criativas e estratégias inovadoras que não seriam previstas ou programadas diretamente por humanos.
- Permite adaptação contínua do modelo caso as regras ou o ambiente mudem ao longo do tempo.

■ DESVANTAGENS:


- Pode ser extremamente custoso e demorado para treinar, pois requer milhares ou milhões de tentativas e muito poder computacional.
- A definição do sistema de "recompensa e punição" pode ser difícil (se a recompensa for mal planejada, a IA pode encontrar atalhos falhos ou apresentar comportamentos imprevisíveis).

TIPOS DE APRENDIZADO








Fonte: <https://www.youtube.com/watch?v=NZlYr1sIAk>




Fonte: https://www.youtube.com/watch?v=8tq1C8spV_g



INTERPRETABILIDADE E FLEXIBILIDADE




INTERPRETABILIDADE E FLEXIBILIDADE



A Gentle Introduction to....



...Machine Learning!!!



Fonte: <https://www.youtube.com/watch?v=ukzFI9rgwfU>



Fonte: <https://www.youtube.com/watch?v=4RixMPF4xis&t=2s>


TÓPICO 2

CICLO DE VIDA DE UM PROJETO DE DADOS


PROCESSO DE APRENDIZADO DE MÁQUINA




**DEFINIÇÃO DO
PROBLEMA**




**COLETA DE
DADOS**




**PREPARAÇÃO
DE DADOS**



**SELEÇÃO DE
ALGORÍTMO**




**TREINAMENTO
DO MODELO**



**AValiação DO
MODELO**

CICLO DE VIDA DE UM PROJETO (CRISP-DM)



**Cross-Industry Standard
Process for Data Mining**

TÓPICO 3

FORMULAÇÃO DE PROBLEMAS: TRADUZINDO DORES DE NEGÓCIO EM TAREFAS DE ML

VALOR ESTRATÉGICO

- **O Cenário Ideal:** Alto volume de dados históricos, necessidade de decisões estruturadas em escala e processos onde a precisão impacta diretamente o risco e o retorno.
- **O Grande Trunfo (Predição vs. Reação):** Minimizar impactos e riscos ao prever cenários futuros, abandonando a postura puramente reativa na tomada de decisão.
- **Sinergia Humano-Máquina:** O ML não substitui o especialista de negócios (domínio), mas o potencializa, automatizando a descoberta de padrões complexos.
- **Diferencial Competitivo:** Deixou de ser inovação isolada para se tornar uma tecnologia essencial para eficiência operacional, personalização e escalabilidade.

PANORAMA: TENDÊNCIAS GLOBAIS E DESAFIOS

GRANDES TENDÊNCIAS	DESAFIOS ESTRATÉGICOS
Hiperpersonalização em Escala: adequação de produtos, serviços e comunicação ao comportamento individual do cliente em tempo real.	Alinhamento e Métricas (KPIs): garantir que o modelo resolva uma dor real e que suas métricas técnicas reflitam ganhos financeiros reais.
IA Generativa Integrada: uso massivo de GenAI para geração de insights, relatórios automatizados e relacionamento com o cliente.	Ética, Vieses e Explicabilidade: evitar modelos "caixa-preta" e garantir que decisões automatizadas sejam justas, auditáveis e interpretáveis.
Uso de Dados Não-Estruturados: aumento do valor extraído de textos, áudios e imagens para segurança, análise de sentimento e automação.	Governança e Privacidade Conformidade regulatória (ex: LGPD): proteção contra ataques cibernéticos e manutenção da qualidade dos dados.

NA PRÁTICA: TRADUZINDO A DOR PARA O MODELO

RETENÇÃO DE CLIENTES

"Estamos perdendo nossos melhores clientes e não sabemos o porquê."



Predição de Churn (Classificação)

Identificar a probabilidade (0 a 100%) de um cliente cancelar o serviço no próximo mês.

CRESCIMENTO DE RECEITA

"Como faço para aumentar o ticket médio das compras no meu site?"



Sistema de Recomendação

Sugerir produtos baseados no histórico do usuário e em clientes com perfil semelhante.

EFICIÊNCIA OPERACIONAL

"Nossa equipe perde horas triando e encaminhando e-mails de suporte."



Processamento de Linguagem (NLP)

Classificação multiclasse automática do texto do e-mail para o departamento correto.

OTIMIZAÇÃO DE CADEIA

"Qual deve ser o nosso nível de estoque de cada produto para o próximo trimestre?"



Previsão de Demanda (Séries Temporais)

Regressão para estimar a quantidade exata de vendas futuras com base no histórico.



Fonte: <https://www.youtube.com/watch?v=me3QEYPsFWE&t=2s>



Fonte: <https://www.youtube.com/watch?v=reUZRyXxUs4>




TÓPICO 4

VIÉS, VARIÂNCIA, OVERFITTING E UNDERFITTING


VIÉS E VARIÂNCIA

- Conceitos que estão relacionados com a precisão e a generalização dos modelos;
- VIÉS:
 - É o erro sistemático que o modelo comete;
 - Ocorre quando o modelo não consegue aprender corretamente a relação entre variáveis de entrada de de saída;
 - Relação forte com o conceito de *underfit*.
- VARIÂNCIA:
 - Grau de variação na previsão do modelo;
 - Ocorre quando o modelo é muito sensível aos dados de treinamento;
 - Relação forte com o conceito de *overfit*.




VIÉS E VARIÂNCIA



VIÉS E VARIÂNCIA



VIÉS E VARIÂNCIA




VIÉS E VARIÂNCIA

LOW BIAS / LOW VARIANCE

O Cenário Ideal: O modelo é preciso e consistente. O que significa: As previsões estão centradas no alvo (baixo viés) e estão todas agrupadas juntas (baixa variância). É o modelo que "acertou o ponto ideal" de complexidade, generalizando bem para dados novos.

HIGH BIAS / LOW VARIANCE

O Problema do Underfitting: O modelo é consistente, mas consistentemente errado. O que significa: O modelo é muito simples (como uma linha reta tentando prever uma curva). Ele ignora as nuances dos dados e erra o alvo sistematicamente. Não importa quantos dados novos você dê, ele continuará errando pela mesma distância porque sua "crença" sobre os dados está incorreta..




Fonte: <https://www.endtoend.ai/blog/bias-variance-tradeoff-in-reinforcement-learning/>

LOW BIAS / HIGH VARIANCE


O Problema do Overfitting: O modelo é preciso na média, mas muito instável. O que significa: O modelo "decorou" o ruído dos dados de treino. Se mudarmos um pouco os dados de entrada, a previsão salta para longe. Ele é complexo demais; no alvo, os pontos rodeiam o centro, mas estão espalhados. Ele não tem consistência ao lidar com dados que nunca viu antes.

HIGH BIAS / HIGH VARIANCE


O Pior dos Mundos: O modelo é impreciso e inconsistente. O que significa: Este é o cenário onde o modelo não conseguiu aprender o padrão (viés alto) e ainda assim é errático em suas respostas (variância alta). Geralmente ocorre com algoritmos mal configurados ou dados de baixíssima qualidade/insuficientes.



VIÉS E VARIÂNCIA



Fonte: <https://www.endtoend.ai/blog/bias-variance-tradeoff-in-reinforcement-learning/>




Fonte: <https://www.kindsonthegenius.com/machine-learning-101-bias-variance-trade-off/>

OVER E UNDERFITTING

GENERALIZAÇÃO:


- É a capacidade de um modelo aprender com os dados de treinamento e fazer previsões precisas em novos dados que nunca viu antes.
- Exemplo:
 - Modelo para classificar imagens de gatos e cachorros. É construído com imagens desses animais de forma variada. O modelo aprende a classificar as imagens com precisão.
 - Em seguida, o modelo é **testado** com um novo conjunto de imagens que nunca antes teve contato. O modelo é capaz de classificar as imagens novas com a **mesma precisão** que as imagens do conjunto de treinamento.



OVER E UNDERFITTING

OVERFITTING:


- Ocorre quando um modelo aprende muito bem os dados de treinamento, mas não é capaz de generalizar para novos dados. Isso pode acontecer quando o modelo é **muito complexo** ou quando o **conjunto de treinamento é muito pequeno**.
- Exemplo:
 - Você treina um modelo e ele aprende a prever o preço dos imóveis com precisão. Quando você testa o modelo em um novo conjunto de dados, os resultados obtidos não são coerentes com o esperado.
 - Isso significa que o modelo aprendeu muito bem os dados específicos do conjunto de treinamento, mas **não foi capaz de aprender as tendências** gerais do mercado imobiliário.



OVER E UNDERFITTING

UNDERFITTING:


- Ocorre quando um modelo não é capaz de aprender suficientemente com os dados de treinamento. Isso pode acontecer quando o **modelo é muito simples**, ou quando o conjunto de **treinamento é muito grande**.
- Exemplo:
 - Você está construindo um modelo para prever o clima de amanhã. Os resultados na base de treino não são bons.
 - Além disso, o modelo não é capaz de prever o clima de amanhã com precisão. Isso significa que o modelo “*underfitou*” os dados de treinamento, não sendo capaz de aprender suficientemente com os dados históricos para fazer previsões precisas.



OVER E UNDERFITTING

EVITANDO OVERFITTING E UNDERFITTING:

- **Conjunto de Validação:** Um conjunto de validação é um conjunto de dados separado do conjunto de treinamento e do conjunto de teste. O conjunto de validação é usado para avaliar o modelo durante o treinamento e evitar *overfitting*.
- **Regularização:** A regularização é uma técnica que penaliza modelos muito complexos. Isso ajuda a evitar *overfitting*, mas também pode levar a *underfitting*.
- **Usar um modelo mais simples:** Se um modelo complexo não está generalizando bem para novos dados, é possível tentar usar um modelo mais simples. Isso pode ajudar a evitar *overfitting*, mas também pode levar a *underfitting*.



OVER E UNDERFITTING

