

DOCUMENTAÇÃO DO PROJETO FINAL DE MACHINE LEARNING

Autor: Matheus Lopes Lourenço

E-Mail: 1666264@pucminas.edu.br

Data: 23/09/2026

Sumário

Visão Geral do Projeto	3
Análise Exploratória.....	3
Estrutura da Base	Erro! Indicador não definido.
Distribuição da variável alvo	Erro! Indicador não definido.
Descrição da Base.....	Erro! Indicador não definido.
Dentre Outros (Valores N/A e Null, Outliers,	Erro! Indicador não definido.
Conclusão	Erro! Indicador não definido.
Feature Engineering	4
Seleção de Modelos de Feature	4
Modelagem e validação	5
Hyperparameter Tuning	6
Avaliação Final.....	6
Interpretabilidade com SHAP	7
Conclusão do Projeto	8

Visão Geral do Projeto

O Projeto Final consiste no desenvolvimento de um pipeline prático de Machine Learning de ponta a ponta (end-to-end), aplicado a um problema real escolhido pelo próprio aluno. O objetivo é demonstrar domínio técnico e visão de negócio, aplicando com rigor as melhores práticas discutidas ao longo da disciplina. Cada aluno deverá escolher um problema real com um conjunto de dados real. A avaliação recai sobre o rigor metodológico do pipeline — não sobre o dataset escolhido. O aluno tem total liberdade para escolher o dataset e o problema de negócio. Datasets públicos de plataformas como Kaggle, UCI ML Repository, Google Dataset Search ou dados reais do contexto profissional são bem-vindos.

Disponibilizado no Kaggle e originalmente proveniente do UCI Machine Learning Repository, contém informações de 30 mil clientes de cartão de crédito, incluindo características demográficas, limite de crédito, histórico de pagamentos, valores das faturas e pagamentos realizados nos meses anteriores. O principal objetivo da base é possibilitar a previsão de inadimplência no mês seguinte, tornando-a adequada para o desenvolvimento de um problema de classificação supervisionada. A variedade de variáveis financeiras e comportamentais também permite aplicar técnicas de análise exploratória, Feature Engineering, seleção de atributos, comparação de modelos de Machine Learning, otimização de hiperparâmetros e técnicas de interpretabilidade, como SHAP.

Característica	Resultado
Observações	30.000 clientes
Colunas originais	25
Variável target	default payment next month
Variáveis preditoras após remoção do ID	24
Divisão dos dados	80% treino / 20% teste
Estratificação	Sim, mantendo a proporção das classes
Conjunto de teste	6.000 observações

Análise Exploratória

Foram realizadas análises iniciais para observar se a base atendia as seguintes etapas:

- Estrutura da base
- Distribuição da variável alvo
- Nulos e duplicidades
- Distribuições
- Outliers
- Correlações

Verificação	Resultado principal
Valores ausentes	Não foram identificados valores nulos/NaN na base original
Duplicidades	Não foram identificados registros duplicados
Classe de default	22,12% dos clientes apresentam default
Classe sem default	77,88% dos clientes
Outliers	Maior concentração em BILL_AMT e PAY_AMT
Tratamento de outliers	Valores extremos não foram removidos automaticamente

Feature Engineering

Foram criadas métricas agregadas para representar o comportamento financeiro dos clientes e reduzir a dependência de uma única observação mensal.

Feature	Descrição
AVG_BILL_AMT	Média das faturas dos seis meses
MAX_BILL_AMT	Maior valor de fatura observado
AVG_PAY_AMT	Média dos pagamentos dos seis meses
MAX_PAY_AMT	Maior pagamento observado
PAYMENT_RATIO	Relação entre pagamento médio e fatura média
CREDIT_UTILIZATION	Relação entre fatura média e limite de crédito
NUM_DELAYED_MONTHS	Quantidade de meses com indicador de atraso > 0
MAX_PAYMENT_DELAY	Maior valor de atraso observado

Seleção de Modelos de Feature

Método	Como seleciona	Vantagem	Desvantagem
Boruta / BorutaPy	Compara importância das features com variáveis "sombreadas"	Muito bom para justificar relevância	Mais pesado computacionalmente
SelectKBest	Seleciona as K melhores pelo teste estatístico	Simple e rápido	Pode ignorar interações entre variáveis
RFE	Remove iterativamente as menos importantes	Fácil de explicar	Pode ser lento
RFECV	RFE + validação cruzada para escolher K	Mais rigoroso que RFE	Mais processamento
SelectFromModel	Seleciona com base na importância de um modelo	Muito prático	Depende do modelo escolhido
L1 / Lasso / Logistic L1	Penalização elimina coeficientes	Excelente para modelos lineares	Pode ter dificuldades com variáveis altamente correlacionadas
Mutual Information	Mede dependência entre feature e target	Captura relações não lineares	Não considera interação entre features

Após a aplicação de três métodos de seleção de variáveis — Boruta, SelectFromModel e SelectKBest — optou-se pelo ****Boruta como método principal para definição do conjunto de features utilizado na modelagem****. O Boruta apresentou um critério de

seleção baseado na comparação da importância das variáveis originais com variáveis de referência aleatorizadas, permitindo identificar aquelas que apresentam evidência de relevância para a tarefa preditiva. Como resultado, foram selecionadas sete variáveis: `PAY\_0`, `AVG\_PAY\_AMT`, `PAYMENT\_RATIO`, `CREDIT\_UTILIZATION`, `NUM\_DELAYED\_MONTHS` e `MAX\_PAYMENT\_DELAY`. A seleção também preserva features derivadas por conhecimento de domínio, especialmente relacionadas ao comportamento de pagamento, atrasos e utilização do crédito. As demais abordagens foram utilizadas como métodos complementares de comparação, mas não serão utilizadas para definir o conjunto final de variáveis nesta etapa.

Modelagem e validação

Os modelos foram comparados utilizando StratifiedKFold com 5 folds e as métricas ROC-AUC, Accuracy, Precision, Recall e F1-score. A Regressão Logística foi utilizada como baseline supervisionado.

Modelo	ROC-AUC	Accuracy	Precision	Recall	F1
CatBoost	0,7757	0,8187	0,6671	0,3607	0,4680
LightGBM	0,7687	0,8180	0,6647	0,3583	0,4654
XGBoost	0,7468	0,8068	0,6085	0,3554	0,4487
Random Forest	0,7443	0,7990	0,5657	0,3952	0,4652
Logistic Regression	0,7412	0,8090	0,6627	0,2793	0,3928
Dummy Classifier	0,5000	0,7788	0,0000	0,0000	0,0000

Na comparação inicial dos modelos, o CatBoost apresentou o maior valor de ROC-AUC (0,7796), seguido pelo LightGBM (0,7774) e Random Forest (0,7685). O LightGBM apresentou, por outro lado, o maior F1-Score (0,4745), enquanto o XGBoost apresentou o maior Recall (0,3709). Considerando o **ROC-AUC como métrica principal para a comparação inicial**, o **CatBoost foi definido como candidato principal para a etapa de otimização de hiperparâmetros**. Entretanto, a **escolha definitiva do modelo será realizada após o processo de tuning e posterior avaliação no conjunto de teste**.

Observando a etapa de Baseline, os resultados demonstraram que a **Regressão Logística apresentou desempenho superior ao Dummy Classifier**, alcançando ROC-AUC de 0,7412, contra 0,5000 do modelo de referência. Embora a Regressão Logística tenha apresentado Accuracy de 0,8090, seu Recall de 0,2793 evidencia limitações na identificação dos clientes que efetivamente apresentam inadimplência. O Dummy Classifier, por sua vez, obteve Accuracy de 0,7788, mas apresentou Recall, Precision e F1-

Score iguais a zero, reforçando que a acurácia isoladamente pode ser inadequada para esse problema devido ao desbalanceamento das classes.

Dessa forma, a Regressão Logística foi definida como baseline supervisionado para comparação com os modelos mais complexos. A partir dessa referência, a etapa seguinte consiste em avaliar e otimizar modelos de ensemble e boosting, buscando verificar ganhos de desempenho na identificação do risco de inadimplência.

Hyperparameter Tuning

Hyperparameter Tuning do CatBoost, que foi o modelo selecionado na Cross-Validation. A ideia é procurar automaticamente uma combinação de hiperparâmetros que melhore o ROC-AUC, sem utilizar o X_test.

Parâmetro	Melhor valor
learning_rate	0,05
l2_leaf_reg	7
iterations	200
depth	8
Melhor ROC-AUC na busca	0,7817

Avaliação Final

Após o tuning, o CatBoost foi treinado no conjunto de treino com as seis features do Boruta e avaliado no conjunto de teste de 6.000 observações.


Métrica	Resultado no teste
ROC-AUC	0,7767
Accuracy	0,8170
Precision	0,6588
Recall	0,3580
F1-score	0,4639

Na classe de default, o relatório de classificação apresentou Precision de 0,66, Recall de 0,36 e F1-score de 0,46. Portanto, **o modelo apresenta capacidade discriminativa moderada, mas ainda deixa uma parcela relevante dos defaults sem identificação quando utilizado o limiar padrão de classificação.**

Interpretabilidade com SHAP

A interpretabilidade foi realizada sobre o CatBoost otimizado utilizando as seis features selecionadas pelo Boruta. Foram utilizados o gráfico de importância global e o Waterfall para explicação local.

Ordem	Variável	Interpretação
1	PAY_0	Status do pagamento mais recente
2	AVG_PAY_AMT	Valor médio dos pagamentos
3	CREDIT_UTILIZATION	Utilização do crédito
4	NUM_DELAYED_MONTHS	Número de meses com atraso
5	MAX_PAYMENT_DELAY	Maior atraso observado
6	PAYMENT_RATIO	Razão entre pagamentos e faturas



O gráfico SHAP de importância média absoluta indica que PAY_0, AVG_PAY_AMT e CREDIT_UTILIZATION possuem maior influência global nas previsões, seguidos por NUM_DELAYED_MONTHS, MAX_PAYMENT_DELAY e PAYMENT_RATIO.

Para um cliente classificado como default, NUM_DELAYED_MONTHS = 6 foi o principal fator de aumento da previsão (+1,18), seguido por MAX_PAYMENT_DELAY = 2 (+0,34) e CREDIT_UTILIZATION = 0,469 (+0,25). AVG_PAY_AMT = 1.823,67 contribuiu com +0,08, enquanto PAYMENT_RATIO = 0,043 reduziu a previsão em -0,37. O PAY_0 = 1 teve impacto mínimo (+0,01), resultando em $f(x) = 0,065$.

1. Número de meses com atraso (NUM_DELAYED_MONTHS) = 6 → contribuição de +1,18, principal fator de aumento da previsão.

2. Maior atraso no pagamento (MAX_PAYMENT_DELAY) = 2 → +0,34, aumentando a previsão.
3. Utilização do crédito (CREDIT_UTILIZATION) = 0,469 → +0,25, contribuindo para maior risco previsto.
4. Valor médio dos pagamentos (AVG_PAY_AMT) = 1.823,67 → +0,08, pequeno aumento.
5. Status do pagamento mais recente (PAY_0) = 1 → +0,01, impacto praticamente neutro.
6. Razão entre pagamentos e faturas (PAYMENT_RATIO) = 0,043 → -0,37, reduzindo a previsão.

Conclusão do Projeto

O projeto demonstrou um pipeline completo de classificação para previsão de inadimplência, desde a análise exploratória até a seleção de atributos, comparação de modelos, tuning e explicabilidade. O CatBoost otimizado apresentou ROC-AUC de 0,7767 no conjunto de teste e as análises SHAP destacaram principalmente variáveis associadas ao comportamento de pagamento e à utilização do crédito.

E o SHAP indica que PAY_0, AVG_PAY_AMT e CREDIT_UTILIZATION são as variáveis de maior influência global nas previsões do CatBoost. No Summary Plot, valores altos de PAY_0, CREDIT_UTILIZATION, NUM_DELAYED_MONTHS e MAX_PAYMENT_DELAY tendem a aumentar a saída do modelo, enquanto valores altos de AVG_PAY_AMT tendem a reduzi-la. Para o cliente analisado, NUM_DELAYED_MONTHS = 6 foi o principal fator de aumento (+1,18), seguido por MAX_PAYMENT_DELAY = 2 (+0,34) e CREDIT_UTILIZATION = 0,469 (+0,25). Já PAYMENT_RATIO = 0,043 reduziu a previsão (-0,37).

O resultado do caso foi $f(x) = 0,065$, na escala de saída do modelo, correspondente a aproximadamente 51,6% quando convertido pela função logística. Assim, o SHAP permite explicar tanto quais variáveis mais influenciam o modelo globalmente quanto quais fatores determinaram uma previsão individual.

Um detalhe importante para o relatório, não há contradição entre:

- PAY_0 ser a variável mais importante globalmente;
- e NUM_DELAYED_MONTHS ser o maior fator no cliente específico.

O primeiro resultado vem do impacto médio no conjunto de teste; o segundo vem da explicação de uma única observação.