

Disciplina:

MACHINE LEARNING

Professor: Rafael Barroso




TÓPICO 1

TUNING DE HIPERPARÂMETROS: GRID/RANDOM SEARCH E OPTUNA

TUNING — FUNDAMENTOS

PARÂMETROS vs. HIPERPARÂMETROS

PARÂMETROS • APRENDIDOS NO TREINO




- **Aprendidos nos dados:** a otimização estima pesos, interceptos e limiares de split.
- **Mudam a cada ajuste:** dependem da amostra, da função de perda e do treinamento.

ANALOGIA DO RÁDIO

O circuito aprende a decodificar o sinal; os botões definem frequência, sintonia e volume. **Ajustar os botões muda o resultado sem trocar o rádio.**

HIPERPARÂMETROS • DEFINIDOS ANTES




- **Controlam o comportamento:** capacidade, regularização e dinâmica de aprendizagem.
- **Não são aprendidos diretamente:** outra configuração pode gerar outro modelo com o mesmo algoritmo.

TUNING — DESAFIO

O ESPAÇO DE BUSCA CRESCE
EXPONENCIALMENTE

$10^5 = 100.000$
configurações

- **Produto cartesiano:** 5 hiperparâmetros $\times$ 10 valores = 10^5 configurações.
- **Validação cruzada multiplica:** com 5 folds, são 500.000 ajustes de modelo.
- **Cada novo eixo custa caro:** outro hiperparâmetro com 10 valores eleva a busca a 10^6 .
- **Objetivo real:** usar o orçamento nas regiões mais informativas, não visitar tudo.



TUNING — MÉTODO CLÁSSICO

GRIDSEARCHCV: FORÇA BRUTA


- **param_grid**: constrói o produto cartesiano dos valores definidos.
- **CV + scoring**: cada configuração é avaliada nos mesmos folds e pela mesma métrica.
- **Seleção**: `best_params_` vence; `refit=True` treina o estimador final com todos os dados de treino.
- **Limite conceitual**: o “ótimo” só existe dentro da grade — valores intermediários não são testados.

VANTAGEM

Determinístico e auditável; ideal em espaços **pequenos e discretos**.

LIMITE

O custo multiplica e repete valores **pouco informativos**.



**25/25 combinações
avaliadas**

TUNING — MÉTODO CLÁSSICO

GRIDSEARCHCV: FORÇA BRUTA

GridSearchCV — scikit-learn 1.0.2

Peça ao Gemini

scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

learn

Install User Guide API Examples Community More

PredefinedSplit
RepeatedKFold
RepeatedStratifiedKFold
ShuffleSplit
StratifiedGroupKFold
StratifiedKFold
StratifiedShuffleSplit
TimeSeriesSplit
check_cv
train_test_split
GridSearchCV
HalvingGridSearchCV
HalvingRandomSearchCV
ParameterGrid
ParameterSampler
RandomizedSearchCV
FixedThresholdClassifier
TunedThresholdClassifierCV
cross_val_predict
cross_val_score
cross_validate
learning_curve
permutation_test_score
validation_curve
LearningCurveDisplay
ValidationCurveDisplay
sklearn.multiclass
sklearn.multioutput
sklearn.naive_bayes
sklearn.neighbors
sklearn.neural_network
sklearn.pipeline
sklearn.preprocessing
sklearn.random_projection
sklearn.semi_supervised
sklearn.svm
sklearn.tree
sklearn.utils

API Reference

sklearn.model_selection

GridSearchCV

GridSearchCV

`class sklearn.model_selection.GridSearchCV(estimator, param_grid, scoring=None, n_jobs=None, refit=True, cv=None, verbose=0, pre_dispatch='2*n_jobs', error_score=nan, return_train_score=False)` [\[source\]](#)

Exhaustive search over specified parameter values for an estimator.

Important members are fit, predict.

GridSearchCV implements a "fit" and a "score" method. It also implements "score_samples", "predict", "predict_proba", "decision_function", "transform" and "inverse_transform" if they are implemented in the estimator used.

The parameters of the estimator used to apply these methods are optimized by cross-validated grid-search over a parameter grid.

Read more in the [User Guide](#).

Parameters:

estimator : estimator object

This is assumed to implement the scikit-learn estimator interface. Either estimator needs to provide a `score` function, or `scoring` must be passed.

param_grid : dict or list of dictionaries

Dictionary with parameters names (`str`) as keys and lists of parameter settings to try as values, or a list of such dictionaries, in which case the grids spanned by each dictionary in the list are explored. This enables searching over any sequence of parameter settings.

scoring : str, callable, list, tuple or dict, default=None

Strategy to evaluate the performance of the cross-validated model on the test set.

If `scoring` represents a single score, one can use:

- a single string (see [String name scorers](#));
- a callable (see [Callable scorers](#)) that returns a single value;
- None, the `estimator`'s [default evaluation criterion](#) is used.

If `scoring` represents multiple scores, one can use:

- a list or tuple of unique strings;
- a callable returning a dictionary where the keys are the metric names and the values are the metric scores;
- a dictionary with metric names as keys and callables as values.

See [Specifying multiple metrics for evaluation](#) for an example.

n_jobs : int, default=None

Number of jobs to run in parallel. None means 1 unless in a [joblib.parallel_backend](#) context.

On this page

GridSearchCV
decision_function
fit
get_metadata_routing
get_params
inverse_transform
predict
predict_log_proba
predict_proba
score
score_samples
set_callbacks
set_params
transform
Gallery examples

scikit-learn is [financially supported](#) by Probabl and other institutions.
:probabl.
[Enterprise-grade solutions and services](#)


TUNING — BUSCA ESTOCÁSTICA

RANDOMIZEDSEARCHCV

- **n_iter** define o orçamento: a busca para após um número fixo de configurações.
- **param_distributions**: sorteia valores contínuos; escalas log-uniformes ajudam em learning_rate e regularização.
- **Cobertura por dimensão**: cada tentativa pode testar um valor novo no hiperparâmetro realmente influente.
- **Reprodutibilidade**: random_state repete os sorteios; a amostragem não garante cobertura exaustiva.

INTUIÇÃO

A vantagem aparece quando poucas dimensões explicam a maior parte da variação de desempenho — a **dimensionalidade efetiva** é baixa.



10 sorteios • 10 valores distintos

TUNING — BUSCA ESTOCÁSTICA

RANDOMIZEDSEARCHCV

RandomizedSearchCV — scikit-learn

scikit-learn.org/stable/modules/generated/sklearn.model_selection.RandomizedSearchCV.html#sklearn.model_selection.RandomizedSearchCV

learn

Install User Guide API Examples Community More

PredefinedSplit

RepeatedKFold

RepeatedStratifiedKFold

ShuffleSplit

StratifiedGroupKFold

StratifiedKFold

StratifiedShuffleSplit

TimeSeriesSplit

check_cv

train_test_split

GridSearchCV

HalvingGridSearchCV

HalvingRandomSearchCV

ParameterGrid

ParameterSampler

RandomizedSearchCV

FixedThresholdClassifier

TunedThresholdClassifierCV

cross_val_predict

cross_val_score

cross_validate

learning_curve

permutation_test_score

validation_curve

LearningCurveDisplay

ValidationCurveDisplay

sklearn.multiclass

sklearn.multioutput

sklearn.naive_bayes

sklearn.neighbors

sklearn.neural_network

sklearn.pipeline

sklearn.preprocessing

sklearn.random_projection

sklearn.semi_supervised

sklearn.svm

sklearn.tree

sklearn.utils

API Reference

sklearn.model_selection

RandomizedSearchCV

RandomizedSearchCV

```
class sklearn.model_selection.RandomizedSearchCV(estimator, param_distributions, *, n_iter=10, scoring=None, n_jobs=None, refit=True, cv=None, verbose=0, pre_dispatch='2*n_jobs', random_state=None, error_score=nan, return_train_score=False) [source]
```

Randomized search on hyper parameters.

RandomizedSearchCV implements a “fit” and a “score” method. It also implements “score_samples”, “predict”, “predict_proba”, “decision_function”, “transform” and “inverse_transform” if they are implemented in the estimator used.

The parameters of the estimator used to apply these methods are optimized by cross-validated search over parameter settings.

In contrast to GridSearchCV, not all parameter values are tried out, but rather a fixed number of parameter settings is sampled from the specified distributions. The number of parameter settings that are tried is given by `n_iter`.

If all parameters are presented as a list, sampling without replacement is performed. If at least one parameter is given as a distribution, sampling with replacement is used. It is highly recommended to use continuous distributions for continuous parameters.

Read more in the [User Guide](#).

Added in version 0.14.

Parameters:

estimator : estimator object
An object of that type is instantiated for each grid point. This is assumed to implement the scikit-learn estimator interface. Either estimator needs to provide a `score` function, or `scoring` must be passed.

param_distributions : dict or list of dicts
Dictionary with parameters names (`str`) as keys and distributions or lists of parameters to try. Distributions must provide a `rvs` method for sampling (such as those from `scipy.stats.distributions`). If a list is given, it is sampled uniformly. If a list of dicts is given, first a dict is sampled uniformly, and then a parameter is sampled using that dict as above.

n_iter : int, default=10
Number of parameter settings that are sampled. `n_iter` trades off runtime vs quality of the solution.

scoring : str, callable, list, tuple or dict, default=None
Strategy to evaluate the performance of the cross-validated model on the test set.
If `scoring` represents a single score, one can use:

On this page

RandomizedSearchCV

decision_function

fit

get_metadata_routing

get_params

inverse_transform

predict

predict_log_proba

predict_proba

score

score_samples

set_callbacks

set_params

transform

Gallery examples

scikit-learn is financially supported by Probabl and other institutions.

probabl.
Enterprise-grade solutions and services

TUNING — BUSCAS

CLÁSSICA vs. ESTOCÁSTICA




Figure 1: Grid and random search of nine trials for optimizing a function $f(x,y) = g(x) + h(y) \approx g(x)$ with low effective dimensionality. Above each square $g(x)$ is shown in green, and left of each square $h(y)$ is shown in yellow. With grid search, nine trials only test $g(x)$ in three distinct places. With random search, all nine trials explore distinct values of g . This failure of grid search is the rule rather than the exception in high dimensional hyper-parameter optimization.

TUNING — OPTUNA

COMO FUNCIONA

FUNÇÃO OBJETIVO

- Definida pelo usuário
- Em cada rodada, recebe uma combinação de valores
- Retorna o resultado da avaliação da rodada


TENTATIVA (TRIAL)

- É uma composição de valores para atender aos (hiper)parâmetros sendo avaliados
- É a entrada da função objetivo

EXPERIMENTO (STUDY)

- É o conjunto de tentativas na busca pela otimização dos parâmetros

STUDY



TUNING — OPTUNA

COMO FUNCIONA

```
import optuna

def objective(trial):
    x = trial.suggest_float('x', -10, 10)
    return (x - 2) ** 2

study = optuna.create_study()
study.optimize(objective, n_trials=100)

study.best_params # E.g. {'x': 2.002108042}
```

```
import optuna

def objective(trial):
    # Categorical parameter
    optimizer = trial.suggest_categorical("optimizer", ["MomentumSGD", "Adam"])

    # Integer parameter
    num_layers = trial.suggest_int("num_layers", 1, 3)

    # Integer parameter (log)
    num_channels = trial.suggest_int("num_channels", 32, 512, log=True)

    # Integer parameter (discretized)
    num_units = trial.suggest_int("num_units", 10, 100, step=5)

    # Floating point parameter
    dropout_rate = trial.suggest_float("dropout_rate", 0.0, 1.0)

    # Floating point parameter (log)
    learning_rate = trial.suggest_float("learning_rate", 1e-5, 1e-2, log=True)

    # Floating point parameter (discretized)
    drop_path_rate = trial.suggest_float("drop_path_rate", 0.0, 1.0, step=0.1)
```

TUNING — OPTUNA

optuna.trial.Trial — Optuna 5.0.1

optuna.readthedocs.io/en/stable/reference/generated/optuna.trial.Trial.html

OPTUNA

Search docs

CONTENTS:

Installation

Tutorial

API Reference

- optuna
- optuna.artifacts
- optuna.cli
- optuna.distributions
- optuna.exceptions
- optuna.importance
- optuna.integration
- optuna.logging
- optuna.pruners
- optuna.samplers
- optuna.search_space
- optuna.storages
- optuna.study
- optuna.terminator
- optuna.trial**
 - optuna.trial.Trial**
 - trial
 - optuna.trial.FixedTrial
 - optuna.trial.FrozenTrial

Key FeaturesCode ExamplesInstallationDashboardOptunaHubBlogVideosPaper

/ API Reference / optuna.trial / optuna.trial.Trial

optuna.trial.Trial

`class optuna.trial.Trial(study, trial_id)` [\[source\]](#)

A trial is a process of evaluating an objective function.

This object is passed to an objective function and provides interfaces to get parameter suggestion, manage the trial's state, and set/get user-defined attributes of the trial.

Note that the direct use of this constructor is not recommended. This object is seamlessly instantiated and passed to the objective function behind the `optuna.study.Study.optimize()` method; hence library users do not care about instantiation of this object.

Parameters:

- `study` (*Study*) – A `study` object.
- `trial_id` (*int*) – A trial ID that is automatically generated.

Methods

<code>report</code> (value, step)	Report an objective function value for a given step.
<code>set_constraint</code> (key, value)	Set a constraint value for the trial.
<code>set_user_attr</code> (key, value)	Set user attributes to the trial.
<code>should_prune</code> ()	Suggest whether the trial should be pruned or not.
<code>suggest_categorical</code> (...)	Suggest a value for the categorical parameter.
<code>suggest_discrete_uniform</code> (name, low, high, q)	Suggest a value for the discrete parameter.
<code>suggest_float</code> (name, low, high, *, step, log)	Suggest a value for the floating point parameter.
<code>suggest_int</code> (name, low, high, *, step, log)	Suggest a value for the integer parameter.
<code>suggest_loguniform</code> (name, low, high)	Suggest a value for the continuous parameter.
<code>suggest_uniform</code> (name, low, high)	Suggest a value for the continuous parameter.

optuna.study.create_study —

optuna.readthedocs.io/en/stable/reference/generated/optuna.study.create_study.html

OPTUNA

Search docs

CONTENTS:

Installation

Tutorial

API Reference

- optuna
- optuna.artifacts
- optuna.cli
- optuna.distributions
- optuna.exceptions
- optuna.importance
- optuna.integration
- optuna.logging
- optuna.pruners
- optuna.samplers
- optuna.search_space
- optuna.storages
- optuna.study**
 - optuna.study.Study
 - optuna.study.create_study**
 - create_study()
 - optuna.study.load_study
 - optuna.study.delete_study
 - optuna.study.copy_study

Key FeaturesCode ExamplesInstallationDashboardOptunaHubBlogVideosPaper

/ API Reference / optuna.study / optuna.study.create_study

optuna.study.create_study

`optuna.study.create_study(*, storage=None, sampler=None, pruner=None, study_name=None, direction=None, load_if_exists=False, directions=None)` [\[source\]](#)

Create a new `study` .

Example

```
import optuna

def objective(trial):
    x = trial.suggest_float("x", 0, 10)
    return x**2

study = optuna.create_study()
study.optimize(objective, n_trials=3)
```

Parameters:

- `storage` (*str* | *storages.BaseStorage* | *None*) – Database URL. If this argument is set to *None*, `InMemoryStorage` is used, and the `study` will not be persistent.

Note


When a database URL is passed, Optuna internally uses [SQLAlchemy](#) to handle the database. Please refer to [SQLAlchemy's document](#) for further details. If you want to specify non-default options to [SQLAlchemy Engine](#), you can instantiate `DBStorage` with your desired options and pass it to the `storage` argument instead of a URL.

- `sampler` (*'samplers.BaseSampler'* | *None*) – A sampler object that implements background algorithm for value suggestion. If *None* is specified, `TPESampler` is used as the default. See also `samplers` .
- `pruner` (*'pruners.BasePruner'* | *None*) – A pruner object that decides early stopping of unpromising trials. If *None* is specified, `MedianPruner` is used as the default. See also `pruners` .
- `study_name` (*str* | *None*) – Study's name. If this argument is set to *None*, a unique name is generated automatically.

TUNING — OPTUNA

TPE PRIORIZA REGIÕES BOAS E EVITA AS RUINS

- **Study:** reúne objetivo, direção, sampler, pruner e histórico de execução.
- **Trial:** representa uma configuração, sua métrica e seu estado — completa, falha ou podada.
- **TPE separa o histórico:** $l(x)$ modela as melhores observações; $g(x)$, as demais.
- **Próxima sugestão:** favorece regiões com $l(x)/g(x)$ alto — densidade boa alta e ruim baixa.



$l(x)$ alta + $g(x)$ baixa → maior probabilidade de um trial promissor


TUNING — EFICIÊNCIA

PRUNING INTERROMPE CEDO O QUE JÁ ESTÁ INDO MAL

- **trial.report(value, step):** envia ao estudo a métrica intermediária por época, árvore ou iteração.
- **Comparação justa:** o pruner confronta o trial com execuções anteriores no mesmo estágio.
- **trial.should_prune():** interrompe configurações sem perspectiva e libera CPU/GPU para novas tentativas.
- **Proteção contra ruído:** warmup e número mínimo de trials evitam podar cedo modelos que aprendem devagar.

DECISÃO

*Se um trial já fracassa na época 5, não pague automaticamente pelas 95 restantes — **mas só decida após um warmup confiável.***



TUNING — SÍNTESE

ESCOLHA O MÉTODO PELO ORÇAMENTO E PELO ESPAÇO DE BUSCA

MÉTODO	USA HISTÓRICO?	ORÇAMENTO	COBERTURA	PODA	ESCOLHA QUANDO...
Grid Search	Não	Todas as combinações	Restrita aos valores da grade	Não	Espaço pequeno, discreto e bem delimitado
Random Search	Não	n_iter fixo	Ampla em cada dimensão	Não	Poucas dimensões dominam o desempenho
Optuna (TPE)	Sim	Adaptativo	Concentra nas regiões promissoras	Sim	Treinos caros e espaços amplos ou condicionais

REGRA DE BOLSO

Grid confirma hipóteses • Random cobre o espaço • Optuna aprende com o histórico e encerra cedo.

TÓPICO 2

INTRODUÇÃO À IA EXPLICÁVEL (XAI)

XAI — DEFINIÇÃO

XAI TRANSFORMA UMA PREDIÇÃO EM UMA DECISÃO JUSTIFICÁVEL

- **Objetivo:** permitir que pessoas compreendam, contestem e confiem nas saídas do modelo.
- **Não basta prever:** “crédito negado” é um resultado; a explicação identifica os fatores que sustentaram a decisão.
- **Públicos diferentes:** cientistas precisam depurar; gestores, decidir; auditoria, rastrear; clientes, receber justificativas.
- **Explicação útil:** deve ser fiel ao modelo, compreensível ao usuário e relevante para a ação.

DA CAIXA-PRETA À PRESTAÇÃO DE CONTAS



XAI adiciona: fatores + direção + magnitude + contexto


EXEMPLO DE NEGÓCIO

“Crédito negado” informa o desfecho. “Endividamento alto e histórico irregular aumentaram o risco” orienta revisão e ação.

XAI — TRADE-OFF

MAIOR FLEXIBILIDADE AUMENTA O PODER PREDITIVO — E O CUSTO DE EXPLICAR

- **Modelos simples:** relações explícitas e poucos graus de liberdade facilitam inspeção e comunicação.
- **Modelos complexos:** capturam não linearidades e interações, mas diluem a decisão entre milhares de operações.
- **Escolha orientada ao risco:** em decisões críticas, uma pequena perda de desempenho pode comprar muita governança.

**DECISÃO DE PROJETO**

Não procure o modelo “mais explicável” ou “mais preciso” isoladamente; **procure o nível de complexidade defensável para o risco da decisão.**

XAI — ARQUITETURAS

CAIXA-BRANCA EXPLICA POR CONSTRUÇÃO; CAIXA-PRETA EXIGE UMA CAMADA DE INTERPRETAÇÃO

CAIXA-BRANCA • INTRÍNSECA

- **Exemplos:** regressão linear/logística, regras e árvores rasas.
- **Leitura direta:** coeficientes, sinais e nós mostram como a saída foi construída.
- **Força:** comunicação e auditoria mais simples quando as relações são estáveis.
- **Limite:** pode perder desempenho ao representar interações complexas.

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

CAIXA-PRETA • PÓS-HOC

- **Exemplos:** Random Forest, Gradient Boosting e redes neurais profundas.
- **Decisão distribuída:** centenas de árvores ou camadas combinam variáveis em hiperespaços.
- **Força:** alta capacidade para padrões não lineares e interações.
- **Limite:** a explicação é uma aproximação ou decomposição posterior, não uma leitura mental do algoritmo.

$$f(x) \rightarrow \text{explicador} \rightarrow \text{contribuições}$$

XAI — ADOÇÃO

UM MODELO SÓ GERA VALOR QUANDO É CONFIÁVEL, GOVERNÁVEL E SEGURO

- **Regulação e compliance:** decisões automatizadas precisam de rastreabilidade, revisão e justificativas compatíveis com LGPD/GDPR.
- **Confiança operacional:** gestores mudam processos quando entendem limites, variáveis decisivas e cenários de falha.
- **Fairness e bias:** explicações ajudam a identificar proxies demográficas e impactos desproporcionais.
- **Gestão de risco:** a equipe consegue definir alçadas humanas para decisões de alto impacto ou baixa confiança.

01

COMPLIANCE

Quem decidiu, com quais sinais?

02

TRUST

A recomendação é operacionalmente plausível?

03

FAIRNESS

Há grupos recebendo impacto indevido?

BARREIRA REAL DE PRODUÇÃO


F1-Score alto prova desempenho no conjunto avaliado; não prova que a decisão é legal, justa, estável ou acionável.

XAI — TAXONOMIA

MÉTODOS AGNÓSTICOS TROCAM FLEXIBILIDADE POR CUSTO; ESPECÍFICOS EXPLORAM A ARQUITETURA

AGNÓSTICO DE MODELO

- **Camada externa:** observa entradas e saídas; funciona com SVM, regressões, redes ou boosting.
- **Vantagem:** padroniza a explicação e permite trocar o estimador.
- **Preço:** costuma exigir muitas chamadas ao modelo e pode aproximar seu comportamento localmente.



MODEL-SPECIFIC

- **Usa a estrutura interna:** coeficientes, splits, gradientes ou propriedades específicas do estimador.
- **Vantagem:** tende a ser mais rápido e fiel à arquitetura.
- **Preço:** a técnica deixa de funcionar quando o modelo muda.



XAI — ESCOPO

GLOBAL EXPLICA O COMPORTAMENTO MÉDIO; LOCAL JUSTIFICA UMA DECISÃO ESPECÍFICA

GLOBAL • VISÃO DO SISTEMA

- **Pergunta:** o que o modelo aprendeu sobre toda a população?
- **Saídas:** ranking de features, efeitos médios, interações e regiões de maior sensibilidade.
- **Uso:** validar coerência, comparar versões e comunicar drivers de mercado.
- **Risco:** médias podem esconder subgrupos e decisões individuais atípicas.

LOCAL • VISÃO DA OBSERVAÇÃO

- **Pergunta:** por que o Cliente João recebeu esta predição hoje?
- **Saídas:** contribuições positivas e negativas em torno do valor basal.
- **Uso:** contestação, atendimento, auditoria e análise de erro.
- **Risco:** uma explicação local não descreve a política global do modelo.

MICROSCÓPIO vs. TELESCÓPIO


O telescópio revela o padrão da constelação; o microscópio examina um ponto. Uma variável discreta no global pode decidir um caso local.

XAI — LIMITES

FEATURE IMPORTANCE RANQUEIA USO — MAS NÃO EXPLICA DIREÇÃO, CONTEXTO OU CAUSA

- **Gini/impurity:** mede quanto uma feature reduziu impureza ao longo dos splits.
- **Sem direção:** uma barra alta não diz se valores altos aumentam ou reduzem a predição.
- **Viés de cardinalidade:** variáveis contínuas ou com muitos níveis oferecem mais pontos de corte e podem ser infladas.
- **Correlação divide crédito:** features redundantes repartem importância de modo instável.
- **Não é causalidade:** uso frequente no modelo não demonstra efeito no mundo real.

RANKING TRADICIONAL



O gráfico responde “quanto foi usado?”, não “como esse valor mudou a decisão?”.

PERGUNTA QUE FICA SEM RESPOSTA

“Renda” é importante — mas renda alta protege ou aumenta o risco? Para responder, precisamos de direção e contribuição.

TÓPICO 3

MÉTODOS DE INTERPRETAÇÃO: SHAP (GLOBAL E LOCAL)

SHAP — ORIGENS

SHAP DISTRIBUI A DIFERENÇA DA PREDIÇÃO COMO UM JOGO COOPERATIVO

- **Valores de Shapley:** solução de 1953 para repartir o ganho de uma coalizão entre jogadores.
- **SHAP:** framework de Lundberg & Lee (2017) que conecta esses valores à explicação de modelos.
- **Jogadores:** features que entram em diferentes coalizões.
- **Pagamento:** diferença entre a saída do modelo e uma referência basal.
- **Justiça matemática:** cada feature recebe sua contribuição marginal média considerando diferentes ordens de entrada.

COALIZÕES E CONTRIBUIÇÕES



PERGUNTA CENTRAL


Se retirarmos uma feature de cada coalizão possível, quanto o resultado muda? A média dessas mudanças define seu crédito.

SHAP — ANALOGIA

A CONTA JUSTA DEPENDE DA CONTRIBUIÇÃO MARGINAL — NÃO DE UMA DIVISÃO IGUAL

- **Conta total:** R\$ 100 para você, Maria e João.
- **Divisão ingênua:** R\$ 33,33 ignora que João pediu um adicional caro e Maria não consumiu sobremesa.
- **Cálculo de Shapley:** mede quanto cada pessoa acrescenta à conta ao entrar em todas as ordens possíveis.
- **Resultado:** a média das contribuições marginais produz uma repartição eficiente e consistente.

CONTRIBUIÇÃO MÉDIA NAS PERMUTAÇÕES



POR QUE TODAS AS ORDENS?

A contribuição de João muda quando ele entra antes ou depois dos demais. A média sobre cenários neutraliza a vantagem da ordem escolhida.

SHAP — TRADUÇÃO PARA ML

FEATURES VIRAM JOGADORES; A PREDIÇÃO ACIMA DO BASELINE VIRA O PAGAMENTO

TEORIA DOS JOGOS	MACHINE LEARNING	EXEMPLO
Jogador	Feature	idade, salário, score
Coalizão	Subconjunto de features	{idade, score}
Valor do jogo	Saída esperada do modelo	probabilidade de risco
Pagamento a repartir	$f(x) - E[f(X)]$	$0,65 - 0,20 = 0,45$
Crédito individual	Valor SHAP ϕ_i	idade contribui +0,15


INTERPRETAÇÃO

Um SHAP de +0,15 não é o valor da feature. É quanto aquela feature empurrou esta predição em relação ao valor de referência.

SHAP — ADITIVIDADE LOCAL

A SOMA DAS CONTRIBUIÇÕES RECONSTRÓI EXATAMENTE A PREDIÇÃO EXPLICADA

$$f(x) = E[f(X)] + \phi_1 + \phi_2 + \dots + \phi_m$$




- **Eficiência local:** nenhum ponto da saída fica sem alocação entre baseline e features.
- **Atenção à escala:** em classificadores, o explicador pode operar em log-odds; confirme antes de interpretar como probabilidade.

RASTREABILIDADE

Baseline + todas as parcelas = saída explicada. *A equação fecha — mas a narrativa ainda precisa respeitar contexto e escala.*

SHAP — ADITIVIDADE LOCAL


A SOMA DAS CONTRIBUIÇÕES RECONSTRÓI EXATAMENTE A PREDIÇÃO EXPLICADA



SHAP — VISÃO GLOBAL


O BEESWARM COMBINA IMPORTÂNCIA, DIREÇÃO E DISTRIBUIÇÃO DO IMPACTO

- **Ordem vertical:** features ranqueadas pela média de $|SHAP|$.
- **Eixo X:** impacto positivo ou negativo na saída do modelo.
- **Cor:** valor observado da feature — baixo em azul, alto em vermelho.
- **Dispersão:** extensão horizontal revela heterogeneidade e possíveis interações.
- **Cada ponto:** uma observação do conjunto explicado.



SHAP — LEITURA GLOBAL


ATRASOS ALTOS AUMENTAM O RISCO; A DISPERSÃO REVELA QUANDO O EFEITO MUDA



SHAP — VISÃO LOCAL

A EXPLICAÇÃO LOCAL PARTE DO BASELINE E MOSTRA COMO CADA FEATURE ALTEROU O CASO

- **Unidade de análise:** uma observação — cliente, paciente, transação ou imóvel.
- **Ponto de partida:** valor médio esperado do modelo no conjunto de referência.
- **Contribuições positivas:** puxam a saída para o evento ou classe analisada.
- **Contribuições negativas:** reduzem a saída em relação ao baseline.
- **Fechamento:** baseline + contribuições = predição individual.



SHAP — TRADE-OFFS

SHAP OFERECE UMA LINGUAGEM ÚNICA — MAS O EXPLICADOR DEVE COMBINAR COM O MODELO E O ORÇAMENTO

CRITÉRIO	TREEEXPLAINER	KERNELEXPLAINER
Modelos	Árvores e ensembles	Qualquer modelo
Estratégia	Usa a estrutura da árvore	Perturba entradas e aproxima localmente
Velocidade	Alta / escalável	Baixa em muitos casos
Fidelidade	Exata ou eficiente no domínio	Depende da amostragem e do background
Melhor uso	XGB, LGBM, RF em produção	Protótipos e modelos sem explicador específico

DECISÃO PRÁTICA

Use o explicador mais específico e eficiente disponível. *Agnosticismo é valioso, mas não torna o custo combinatório gratuito.*

TÓPICO 4

**IA GENERATIVA NA
VALIDAÇÃO: USO DE LLMS
PARA GERAR RELATÓRIOS DE
DIAGNÓSTICO E
INTERPRETAR MÉTRICAS**

LLMs — PAPEL NO PIPELINE

DEPOIS DE OTIMIZAR E EXPLICAR, O DESAFIO É TRADUZIR O DIAGNÓSTICO PARA DECISÃO

- **Entrada técnica:** métricas, variâncias, matrizes de confusão, resíduos e vetores SHAP.
- **Problema:** JSON e tabelas afastam quem precisa decidir sobre risco, custo e operação.
- **Papel do LLM:** estruturar, resumir e traduzir evidências fornecidas — não recalculam a estatística.
- **Saída útil:** achados, impacto, hipótese, limitação e recomendação verificável.
- **Controle:** números e conclusões críticas permanecem sob validação humana.

PONTE ENTRE EVIDÊNCIA E AÇÃO



O LLM atua como “revisor analítico”: organiza evidências e aponta perguntas.
Não substitui o cálculo, o teste estatístico ou a aprovação do especialista.

MUDANÇA DE PAPEL


O modelo fundacional deixa de ser apenas chatbot e vira uma camada de comunicação controlada. A fonte da verdade continua sendo o pipeline.

LLMs — VALIDAÇÃO CRUZADA

MÉDIA MOSTRA DESEMPENHO; DISPERSÃO MOSTRA SE O MODELO É ESTÁVEL ENTRE FOLDS

- **K-Fold:** alterna partições de treino e validação para reduzir dependência de uma única divisão.
- **Entrada agregada:** métricas por fold, média, desvio-padrão, tamanho e distribuição de classes.
- **Diagnóstico assistido:** o LLM compara variabilidade alta com possíveis folds pequenos, raros ou desbalanceados.
- **Limite:** ele sugere hipóteses; somente a inspeção dos folds confirma subamostragem ou leakage.
- **Ação:** repetir CV, estratificar, agrupar ou revisar o esquema de split conforme o problema.

EXEMPLO DE MÉTRICAS POR FOLD



Média = 0,77 • desvio = 0,08
Alerta: Fold 3 merece inspeção de classe, período e origem.

PROMPT RESPONSÁVEL

“Liste hipóteses para a instabilidade e quais evidências confirmariam cada uma.” *Evite pedir uma causa definitiva.*

LLMs — MATRIZ DE CONFUSÃO

O VALOR DO ERRO DEPENDE DO NEGÓCIO — NÃO APENAS DA CONTAGEM NA MATRIZ

EVIDÊNCIA NUMÉRICA

	PRED. NÃO	PRED. SIM
REAL NÃO	TN 8.600	FP 900
REAL SIM	FN 275	TP 225



TRADUÇÃO CONTROLADA

- **Achado:** o modelo captura menos da metade das fraudes reais.
- **Impacto:** falsos negativos podem gerar perda financeira maior que falsos positivos.
- **Hipóteses:** classe minoritária pouco representada, threshold alto ou features insuficientes.
- **Teste recomendado:** avaliar curva Precision–Recall e custo por limiar; testar class_weight no tuning.
- **Restrição:** não recomendar alteração sem informar o custo de revisão dos falsos alarmes.

Recall fraude = 45%
275 fraudes passaram sem alerta.

DO NÚMERO À DECISÃO

O LLM organiza o raciocínio, mas o custo de FN e FP deve vir do negócio. *Sem essa premissa, a recomendação é especulativa.*

LLMs — EXPLICABILIDADE ASSISTIDA

UM VETOR SHAP PODE VIRAR UM RELATÓRIO DE ERRO — DESDE QUE O LLM NÃO INVENTE CONTEXTO

- **Selecione o caso:** erro extremo, outlier operacional ou decisão contestada.
- **Envie contexto mínimo:** predição, valor real, baseline e maiores contribuições SHAP.
- **Peça estrutura:** evidência → hipótese → teste de confirmação → recomendação.
- **Restrinja:** não inferir causalidade, não criar valores ausentes e citar os números recebidos.
- **Valide:** compare o texto com o vetor original e registre versão do prompt/modelo.

EXEMPLO: ERRO IMOBILIÁRIO

erro = R\$ 1.000.000
SHAP distância_metrô = +R\$ 620 mil
SHAP CEP = +R\$ 210 mil

RELATÓRIO GERADO

“A maior contribuição para a superestimação veio de distância_metrô. Verifique unidade, imputação e geocodificação do CEP antes de concluir que o padrão é real.”

BOA SAÍDA

O relatório aponta uma trilha de investigação. *Não declara “erro de imputação” como fato sem evidência.*

LLMs — PROMPT ANALÍTICO

PROMPTS CONFIÁVEIS DEFINEM PAPEL, CONTEXTO, DADOS, TAREFA E LIMITES

01 PAPEL

“Atue como revisor de validação de ML.”

02 CONTEXTO

Objetivo, classe positiva, custo dos erros e população.

03 DADOS

JSON agregado: métricas, folds, SHAP e metadados.

04 TAREFA

Separar achados, hipóteses, testes e ações.

05 RESTRIÇÕES

Usar apenas números fornecidos; declarar incerteza.

ESQUELETO DO PROMPT

```
PAPEL: revisor de ML
CONTEXTO: fraude; FN custa 8x FP
DADOS: {"recall": 0.45, "cv_std": 0.08}
TAREFA: gere achados, hipóteses e testes
RESTRIÇÕES:
- cite somente dados recebidos
- não afirme causalidade
- sinalize informação ausente
```

PRINCÍPIO


Estrutura reduz liberdade desnecessária e melhora consistência. **Ainda assim, toda saída deve ser validada contra a evidência.**

LLMs — GOVERNANÇA

DATA MASKING DEVE ACONTECER ANTES QUE QUALQUER AMOSTRA LOCAL SAIA DO AMBIENTE CONTROLADO

- **Risco crítico:** Local SHAP pode carregar nome, documento, endereço, diagnóstico ou outros dados pessoais.
- **Minimização:** envie apenas campos necessários para a tarefa analítica.
- **Pseudonimização:** substitua identificadores por tokens sem significado externo.
- **Segregação:** mantenha a tabela de reversão em ambiente separado e com acesso controlado.
- **Registro:** audite payload, provedor, retenção, finalidade e versão do modelo de linguagem.

BARREIRA DE PRIVACIDADE



Regra: não envie dados identificáveis a APIs públicas sem base legal, contrato, controles e finalidade explícita.

PRIVACIDADE BY DESIGN

Anonimizar depois do envio é tarde demais. *O filtro precisa estar no pipeline, antes da chamada.*

LLMs — ORQUESTRAÇÃO

AUTOMAÇÃO EM CÓDIGO TRANSFORMA UMA ANÁLISE MANUAL EM UM PROCESSO REPRODUTÍVEL E AUDITÁVEL

- **Coleta:** callbacks capturam métricas, resíduos, alertas e explicações.
- **Parser:** converte os outputs para um esquema JSON validado.
- **Orquestrador:** LangChain ou código próprio aplica template, modelo e política de retry.
- **Validador:** checa schema, citações numéricas, limites e respostas incompletas.
- **Destino:** relatório, ticket, observabilidade ou aprovação humana.

FLUXO AUTOMATIZADO



```
payload = MetricSchema(**metrics)
prompt = template.format(data=payload.json())
response = llm.invoke(prompt)
report = ReportSchema.parse(response)
assert_numbers_grounded(report, payload)
```

PRODUÇÃO

Copiar e colar em um chat não cria rastreabilidade. Código versionado fixa schema, prompt, modelo e validações.

LLMs — AVALIAÇÃO CONTÍNUA

FRAMEWORKS DE AVALIAÇÃO TRANSFORMAM O RELATÓRIO DO LLM EM UM GATE DE QUALIDADE

- **Ragas / DeepEval:** ajudam a medir qualidade de respostas, grounding, relevância e consistência.
- **Gate automático:** falhas críticas bloqueiam promoção; alertas moderados exigem revisão.
- **Regressão:** conjunto de casos dourados detecta deterioração ao trocar prompt, modelo ou dados.
- **Observabilidade:** registre custo, latência, taxa de erro, versão e aprovação humana.
- **Separação de responsabilidades:** o LLM avalia narrativas; testes determinísticos validam números e schemas.

SEQUÊNCIA DO GATE DE QUALIDADE



APROVADO → produção

REPROVADO → evidência + revisão + novo ciclo

Casos dourados detectam regressões ao trocar dados, prompt ou modelo.

CI/CD PARA DIAGNÓSTICOS

A qualidade da narrativa também pode regredir. *Versione e teste o componente generativo como qualquer software.*