

DIRETRIZES DE AVALIAÇÃO

Disciplina: Machine Learning
Professor: Rafael Barroso

1. VISÃO GERAL DA AVALIAÇÃO

A avaliação da disciplina Machine Learning é composta por cinco pilares complementares, totalizando 100 pontos. O modelo avalia tanto o domínio conceitual quanto a capacidade de aplicação prática, integrando atividades ao longo da disciplina com uma entrega final de projeto.

Componente	Pontos	Quando	Descrição Resumida
Projeto Final – Pipeline ML	50	Após o Encontro 6	Pipeline end-to-end completo com dataset de livre escolha
Documentação Técnica do Projeto Final	10	Junto ao Projeto Final	Relatório técnico em PDF detalhando as etapas e decisões
Redação Técnica	10	Prazo definido no Canvas	Texto dissertativo sobre tema contemporâneo de ML
Atividades Práticas (4 × 5 pts)	20	Após encontros 2, 3, 4 e 5	Notebooks práticos com prazo de 7 dias cada
Testes de Múltipla Escolha (Canvas)	10	Ao longo da disciplina	Quizzes objetivos no Canvas por encontro
TOTAL	100	—	Nota mínima para aprovação: 60 pontos

2. PROJETO FINAL – PIPELINE DE MACHINE LEARNING (50 pts)

2.1 Visão Geral

O Projeto Final consiste no desenvolvimento de um pipeline prático de Machine Learning de ponta a ponta (end-to-end), aplicado a um problema real escolhido pelo próprio aluno. O objetivo é demonstrar domínio técnico e visão de negócio, aplicando com rigor as melhores práticas discutidas ao longo da disciplina.

Cada aluno deverá escolher um problema real com um conjunto de dados real. A avaliação recai sobre o rigor metodológico do pipeline — não sobre o dataset escolhido.

O aluno tem total liberdade para escolher o dataset e o problema de negócio. Datasets públicos de plataformas como Kaggle, UCI ML Repository, Google Dataset Search ou dados reais do contexto profissional são bem-vindos.

2.2 Etapas Obrigatórias do Pipeline

O notebook deve implementar obrigatoriamente as seguintes etapas:

- **Análise Exploratória de Dados (EDA)**
 - Verificação de distribuições, detecção analítica/visual de outliers
 - Matriz de correlação e diagnóstico de dados ausentes
 - Uso de ferramentas automatizadas (ex: ydata-profiling) é incentivado
- **Feature Engineering**
 - Imputação de nulos com estratégia justificada
 - Tratamento de outliers (IQR, Winsorização ou transformação log)
 - Encodings adequados para alta e baixa cardinalidade

- Criação de novas features com base em conhecimento de domínio
- Transformações de escala quando necessárias
- **Seleção de Features**
 - Seleção rigorosa das variáveis preditoras utilizando Boruta (via BorutaPy) ou métodos equivalentes (SelectKBest, RFE, SelectFromModel)
- **Modelagem Baseline**
 - Implementação de um estimador simples (Linear, Logístico ou Dummy) para fixar a métrica de referência
- **Modelos de Alta Performance**
 - Treinamento e avaliação comparativa de pelo menos 3 modelos
 - Recomendado: Random Forest, XGBoost, LightGBM e/ou CatBoost
- **Tuning de Hiperparâmetros**
 - Otimização dos parâmetros do melhor modelo usando RandomizedSearchCV, GridSearchCV ou Optuna
- **Interpretabilidade (SHAP)**
 - SHAP Summary Plot (importância global das features)
 - SHAP Waterfall ou Force Plot (análise local de uma amostra individual)
- **IA Generativa como Ferramenta de Apoio**
 - Uso de LLMs (ChatGPT, Copilot, etc.) para brainstorming de features, interpretação de métricas ou geração de código
 - Documentar os prompts utilizados e os resultados obtidos em células Markdown

2.3 Critérios de Avaliação do Projeto Final

Critério	Peso	O que será avaliado
Rigor Metodológico	30%	Rigor estatístico na EDA, tratamento correto de data leakage, aplicação correta de Boruta ou método equivalente
Qualidade da Modelagem	30%	Uso de modelos de alta performance, eficiência do tuning de hiperparâmetros, comparação adequada entre modelos
Explicabilidade	20%	Capacidade de traduzir os valores SHAP em insights compreensíveis, análise global e local corretamente implementadas
Uso de IA Generativa	10%	Integração adequada de LLMs no pipeline, qualidade dos prompts utilizados e documentação do processo
Organização e Clareza	10%	Código bem organizado, células Markdown explicativas, reprodutibilidade do notebook

3. DOCUMENTAÇÃO TÉCNICA DO PROJETO FINAL (10 pts)

Um relatório técnico em formato PDF, redigido com linguagem formal e padrão executivo. Esta documentação traduz o esforço do notebook em um artefato de governança e estratégia de engenharia. Máximo de 8 páginas.

Seção	Conteúdo Esperado
1. Visão Geral do Projeto	Contextualização do problema, justificativa de negócio, objetivo técnico do algoritmo (tipo de problema) e limitações de escopo
2. Arquitetura de Dados e Engenharia	Mapeamento das fontes de dados, estratégias de Feature Engineering e tratamento adotadas
3. Modelagem e Validação	Justificativa da seleção de features, registro do desempenho de todos os modelos testados, estratégia de validação cruzada
4. Interpretabilidade e Resultados	Análise dos impactos de SHAP (Global e Local) traduzidos para linguagem de negócio
5. Conclusões e Próximos Passos	Principais aprendizados, limitações do modelo e sugestões de melhorias futuras

Critério	Peso
Conexão com o Negócio	30%
Clareza e Estrutura	30%
Profundidade Técnica	40%

4. REDAÇÃO TÉCNICA (10 pts)

Produção de um texto dissertativo sobre um tópico contemporâneo de Machine Learning. O objetivo é avaliar a clareza conceitual, a capacidade de síntese e o pensamento crítico do aluno sobre temas relevantes da área.

4.1 Temas sugeridos (o aluno pode propor outro tema, sujeito à aprovação do professor)

- Ética e vieses em algoritmos de Machine Learning
- Explicabilidade e transparência em modelos de IA (XAI)
- O impacto da IA Generativa no fluxo de trabalho de Ciência de Dados
- MLOps: desafios de colocar modelos de ML em produção
- Privacidade de dados e Machine Learning: desafios e soluções
- O futuro do trabalho na era da IA: impactos e oportunidades

Outros temas podem ser escolhidos, não se atenha somente aos listados. Contudo, o tema deve ser relevante ao escopo da disciplina.

4.2 Critérios de Avaliação

Critério	Peso	Descrição
Clareza Conceitual	40%	Domínio do tema, precisão dos conceitos e ausência de imprecisões técnicas
Capacidade de Síntese	30%	Objetividade, coerência argumentativa e organização das ideias
Pensamento Crítico	30%	Análise própria, posicionamento fundamentado e conexão com a realidade do mercado

Formato: texto corrido, entre 500 e 800 palavras, entregue em PDF via Canvas.

⚠ O uso de IA Generativa para redigir o texto é permitido como apoio, mas o aluno deve demonstrar pensamento crítico próprio. Textos gerados integralmente por IA sem análise pessoal serão penalizados.

5. ATIVIDADES PRÁTICAS (4 × 5 pts = 20 pts)

Quatro notebooks práticos entregues ao longo da disciplina, um após cada encontro avaliativo (encontros 2, 3, 4 e 5). Cada atividade vale 5 pontos e tem prazo de 7 dias após o encontro correspondente.

Atividade	Encontro	Tema	Pontos
Atividade 1	2	Pipeline de Pré-Processamento Completo	5
Atividade 2	3	Comparação de Algoritmos de Classificação e Regressão	5
Atividade 3	4	Clustering + Ensemble Learning	5
Atividade 4	5	Avaliação de Modelos: Métricas, Validação Cruzada e SHAP	5

TOTAL	—	—	20
-------	---	---	----

5.1 Critérios de Avaliação das Atividades Práticas

Critério	Peso	Descrição
Corretude Técnica	50%	O código executa corretamente e produz os resultados esperados
Compreensão Conceitual	30%	As células Markdown demonstram entendimento do que está sendo feito e por quê
Organização e Clareza	20%	Código limpo, bem comentado e reproduzível

As atividades ficam disponíveis para realização durante todo o período do curso. A maior nota sempre prevalecerá em caso de reentrega dentro do prazo.

6. TESTES DE MÚLTIPLA ESCOLHA NO CANVAS (10 pts)

Quizzes objetivos disponíveis na plataforma Canvas, aplicados ao longo da disciplina para verificação do domínio conceitual dos conteúdos abordados em cada encontro. Os testes são compostos por questões de múltipla escolha sobre os temas teóricos da disciplina.

Quiz	Encontro	Tema	Pontos
Quiz 1	2	Feature Engineering: pré-processamento, encodings e rescalagem	2,5
Quiz 2	3	Algoritmos supervisionados, não-supervisionados e seleção de features	2,5
Quiz 3	4	Algoritmos de ensemble	2,5
Quiz 4	6	Métricas de avaliação, validação cruzada e explicabilidade	2,5
TOTAL	—	—	10

Cada quiz fica disponível por 7 dias após o fim da disciplina. Após o prazo, o quiz é encerrado automaticamente. Não há segunda tentativa.

⚠ Fique atento ao calendário no Canvas. Os quizzes têm prazo fixo e não serão reabertos após o encerramento.

7. PRAZO E FORMA DE ENTREGA

Componente	Prazo	Forma de Entrega
Projeto Final – Pipeline ML	Conforme calendário no Canvas	Arquivo ipynb (Jupyter Notebook) via Canvas executável e link público para a base de dados (pode ser link para o arquivo no seu Google Drive/OneDrive ou link direto para download). Caso o Notebook não execute e/ou download dos dados não seja DIRETO o trabalho será zerado.
Documentação Técnica	Junto ao Projeto Final	Arquivo PDF via Canvas (máx. 8 páginas)
Redação Técnica	Conforme calendário no Canvas	Arquivo PDF via Canvas (500–800 palavras)
Atividades Práticas	Conforme calendário no Canvas	Arquivo .ipynb via Canvas

Testes de
Múltipla Escolha

Conforme calendário no Canvas

Diretamente na plataforma Canvas

⚠ Entregas fora do prazo sem justificativa prévia terão desconto de 10% por dia de atraso, até o limite de 50% da nota do componente.

8. ORIENTAÇÕES FINAIS

- Comece a pensar no seu problema de negócio e dataset desde o Encontro 1. Quanto mais cedo você definir o tema, mais tempo terá para explorar os dados.
- Faça o split treino/teste ANTES de qualquer pré-processamento (evite data leakage).
- Use `random_state` em todos os modelos para garantir reprodutibilidade.
- Documente os prompts de IA Generativa utilizados em células Markdown dedicadas.
- Em caso de dúvidas, entre em contato preferencialmente por mensagem no Teams, mas podendo também ser pela caixa de entrada do Canvas. O professor responderá assim que possível durante o período ativo da disciplina.