



Pontifícia Universidade Católica de Minas Gerais

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
PRÓ-REITORIA DE PESQUISA E PÓS-GRADUAÇÃO
DIRETORIA DE EDUCAÇÃO CONTINUADA

PLANO DE ENSINO

DISCIPLINA (nome completo): **Modelos de Regressão**

CURSO (nome completo): **Ciência de Dados e Big Data**

PROF (A) (nome completo): **Anaíle Mendes Rabelo**

CARGA HORÁRIA TOTAL (sala de aula + trabalho orientado): **24 H.A**

TRABALHO ORIENTADO (descrição das atividades extracurriculares):

Realização de um projeto prático completo ao fim da disciplina. O aluno deverá escolher um problema real, realizar o tratamento de dados, aplicar uma das técnicas aprendidas (GLM's) e apresentar os resultados através de um dashboard ou relatório técnico.

EMENTA (conforme Projeto Pedagógico):

Regressão Linear Múltipla. Estimação de parâmetros, inferência e estudo de adequação. Problemas de multicolinearidade e heterocedasticidade. Variáveis Dummy. Modelos Lineares Generalizados (GLM): Família Exponencial, componente sistemática e função de ligação. Função desvio (Deviance), Função Escore e Matriz de Fisher. Análise de diagnóstico e aplicação de IA na validação de modelos.

UNIDADES DE ENSINO (Conteúdo Programático):

1 - Regressão Linear Múltipla e Inferência:

- Estimadores de Mínimos Quadrados Ordinários (MQO).
- Testes de Hipóteses para os coeficientes (t e F).
- **Ponto Teórico:** Dedução intuitiva da Variância dos Estimadores.

2 - Adequação e Diagnóstico de Regressão:

- Análise de resíduos, detecção de *outliers* e pontos de alavancagem.
- Multicolinearidade (VIF) e transformações de Box-Cox.
- Uso de Variáveis Dummy (Qualitativas no modelo).

3 - Fundamentos de GLM:

- A Família Exponencial (Normal, Poisson, Binomial, Gamma).
- Funções de Ligação: Identidade, Logit, Log, Inversa.
- **Ponto Teórico:** Máxima Verossimilhança e o papel da Matriz de Informação de Fisher.

4 - Aplicações Especiais e Avaliação de Ajuste:

- Regressão Logística e Regressão de Poisson.
- Análise de Deviance (Função Desvio) e resíduos de Pearson.

5 - IA no Ciclo de Vida da Regressão:

PÓS-GRADUAÇÃO • IEC PUC MINAS

Rua Walter Ianni, 255. Bloco H | São Gabriel | 31980-110 | Belo Horizonte | Minas Gerais | Brasil

Tel.: (31) 3131-2800 | atendimentoiec@pucminas.br



Pontifícia Universidade Católica de Minas Gerais

- Uso de LLMs para auxílio na seleção de modelos e diagnóstico de violação de premissas.

OBJETIVOS (Quais são os resultados esperados ou metas):

- Capacitar o aluno a construir modelos preditivos robustos utilizando os GLM's.
- Implementar estratégias de IA Generativa para acelerar o diagnóstico estatístico e a comunicação de resultados.
- Desenvolver um projeto fim-a-fim que integre modelagem estatística e visualização de dados.

MÉTODOS DIDÁTICOS (Descreva os recursos que serão utilizados):

- **Fundamentação Teórica:** Explicar o "porquê" por trás da Função Escore antes de mostrar o resultado no Python.
- **Refatoração de Código:** Ensinar o aluno a transitar da biblioteca scikit-learn (foco em predição) para a statsmodels (foco em inferência estatística).
- **Laboratórios de IA:** Exercícios onde o aluno utiliza prompts estruturados para interpretar a Matriz de Fisher ou explicar o conceito de Deviance, por exemplo.

DISTRIBUIÇÃO DE PONTOS (Descreva a distribuição de pontos entre as atividades avaliativas):

Lista de exercícios 1 – 15 pontos
Lista de exercícios 2 – 15 pontos
Lista de exercícios 3 – 15 pontos
Trabalho final – 55 pontos

CRITÉRIOS DE AVALIAÇÃO (Especifique e detalhe os critérios sobre informações das avaliações):

- **Rigor Estatístico:** Correção na aplicação dos testes de hipóteses e verificação de pressupostos (ex: homoscedasticidade, normalidade).
- **Qualidade do Código:** Organização, documentação e eficiência na implementação dos algoritmos.
- **Capacidade Analítica:** Interpretação correta das métricas (RMSE, MAE, R^2 , AUC-ROC).
- **Apresentação de Resultados:** Clareza na comunicação dos insights gerados e na construção do dashboard preditivo.

REFERÊNCIAS BIBLIOGRÁFICAS (Liste as fontes de consulta utilizadas no desenvolvimento da disciplina):

- DOBSON, A. J.; BARNETT, A. G. **An Introduction to Generalized Linear Models**. 4. ed. Boca Raton: CRC Press, 2018.
- HOSMER, D. W.; LEMESHOW, S. **Applied Logistic Regression**. 3. ed. Hoboken: John Wiley & Sons, 2013.
- MONTGOMERY, D. C.; PECK, E. A.; VINING, G. G. **Introduction to Linear Regression Analysis**. 5. ed. Hoboken: John Wiley & Sons, 2012.
- NELDER, J. A.; WEDDERBURN, R. W. M. **Generalized Linear Models**. Journal of the Royal Statistical Society, 1972. (Leitura clássica sugerida).